

Distribuciones Multivariadas

José Andrey Zamora Araya

Universidad de Costa Rica

Escuela de Estadística

Curso de Modelos Probabilísticos II (XS-0123)

Distribución Hipergeométrica Multivariada

Al igual que su contraparte univariada, se inicia con una población finita N compuesta por K subconjuntos de objetos de c tipos diferentes, es decir, hay $K_1, K_2, \dots, K_c$ subconjuntos; del que se toma una muestra n de $x_1, x_2, \dots, x_c$ objetos de cada subconjunto. Además, $\sum_{i=1}^c K_i = N$ y $\sum_{i=1}^c x_i = n$.

Por ejemplo, de una población 100 votantes con simpatía por tres partidos políticos P_1, P_2, P_3 , donde 25 simpatizan con P_1 , 35 con P_2 y el resto (40) con P_3 , se elige una muestra de 9 personas y resulta que 3 personas votarán por P_1 , 4 por P_2 y 2 por P_3 .

Ejemplo 1

Acá, $N=100$ y representa el tamaño de la población, $c=3$ que sería la cantidad de tipos de partidos políticos, el vector $K=(25,35,40)$ representa la partición de la población en tres partidos (o tipos de objetos) y el vector $x=(3,4,2)$ representa la cantidad de objetos tomada de cada tipo.

Al igual que en el modelo de muestreo básico, se muestrea n objetos al azar N , sin reemplazo.

Función de densidad conjunta

Sean $X_1, \dots, X_c$ variables aleatorias, de donde se toma una muestra $x_1, \dots, x_c$, tal que $\sum_{i=1}^c K_i = N$ y $\sum_{i=1}^c x_i = n$, donde N representa el tamaño de la población y n el tamaño de la muestra. Entonces la función de densidad conjunta de $X_1, \dots, X_c$, conocida como distribución hipergeométrica multivariada, está dada por:

$$\mathbb{P}(X_1 = x_1, \dots, X_c = x_c) = \frac{\prod_{i=1}^c \binom{K_i}{x_i}}{\binom{N}{n}}$$

Ejemplo 2

En una lista para candidatos a ser jurados hay 6 hombres casados, 3 solteros, 7 mujeres casadas y 4 solteras. Suponga que se hace una selección aleatoria, ¿cuál es la probabilidad de que el jurado consista de 4 hombres casados, un hombre soltero, 5 mujeres casadas y 2 mujeres solteras?

Solución Ejemplo 2

$$\begin{aligned}\mathbb{P}(X_1 = 4, X_2 = 1, X_3 = 5, X_4 = 2) &= \frac{\binom{6}{4} \cdot \binom{3}{1} \cdot \binom{7}{5} \cdot \binom{4}{2}}{\binom{20}{12}} \\ &= \frac{189}{4199} = 0.04501072\end{aligned}$$

Distribución Hipergeométrica Multivariada en R

```
library(extraDistr)
dmvhyper(x, n, k, log = FALSE)
rmvhyper(nn, n, k)
```

donde

x: es una matriz de cuantiles con m columnas

n : Es un vector o matriz de m columnas de números **k**: Es el tamaño de la muestra

log: Si es TRUE, las probabilidades p se dan en $\log(p)$

nn: número de observaciones.

La función de densidad en R

Haciendo los cambios respectivos, R expresa la función de densidad hipergeométrica multivariada de la siguiente forma:

$$\mathbb{P}(X_1 = x_1, \dots, X_c = x_m) = \frac{\prod_{i=1}^m \binom{n_i}{x_i}}{\binom{N}{k}}$$

donde hay m tipos de grupos distintos donde $\sum_{i=1}^m n_i = N$ y

$$\sum_{i=1}^m x_i = k$$

Solución Ejemplo 2 en R

```
library(extraDistr)
set.seed(1609)
dmvhyper(x=c(4,1,5,2), n=c(6,3,7,4), k=12)
```

```
## [1] 0.04501072
```

Ejemplo 3

Para simular 9 valores de una distribución hipergeométrica multivariada, donde se saca una muestra de 33 valores con cinco tipos de objetos y la cantidad total de objetos por tipo sea de 10, 12, 5, 8, 11, se utiliza el siguiente comando

```
rmvhyper(nn=9, n=c(10, 12, 5, 8, 11), k=33)
```

##		[, 1]	[, 2]	[, 3]	[, 4]	[, 5]
##	[1,]	6	8	4	6	9
##	[2,]	7	10	4	4	8
##	[3,]	7	10	4	4	8
##	[4,]	7	10	4	6	6
##	[5,]	7	9	3	5	9
##	[6,]	8	10	2	7	6
##	[7,]	8	8	3	5	9
##	[8,]	7	8	3	5	10
##	[9,]	6	9	4	4	10

Distribución Multinomial

La distribución multinomial es una distribución discreta, multidimensional, que podría verse como una generalización de la distribución binomial o, en su defecto, la distribución binomial sería un caso particular de la distribución multinomial para el caso de dos resultados posibles y mantiene los mismos supuestos, en particular el que las probabilidades se mantienen constantes de ensayo en ensayo, es decir, se asume muestreo con reemplazo.

Distribución Multinomial


Se dice que una variable aleatoria k -dimensional $X = (X_1, X_2, \dots, X_k)$ se dice que tiene una distribución multinomial de parámetros $n, p_1, p_2, \dots, p_k$, es decir, $X \sim M(n, p_1, p_2, \dots, p_k)$ si su función de distribución de probabilidad conjunta esta dada por:

$$p_{X_1, \dots, X_n}(x_1, x_2, \dots, x_k) = \frac{n!}{x_1! \cdot x_2! \cdot \dots \cdot x_k!} \cdot p_1^{x_1} \cdot p_2^{x_2} \cdot \dots \cdot p_k^{x_k}$$

Siempre que

$$\sum_{i=1}^k x_i = n \text{ y } \sum_{i=1}^k p_i = 1$$

Trinomial con $p_1 = p_3 = 0.1, p_2 = 0.8$ y $n=10$



Ejemplo 4 (Miller & Miller, 2004, p. 199)

En una cierta ciudad hay tres estaciones de televisión. Durante el horario de máxima audiencia del sábado en la noche, el canal 12 tiene el 50% de audiencia, el canal 10 el 30% y el canal 3 el 20%. Encuentre la probabilidad de que en una muestra de 8 televidentes en esa ciudad elegidos aleatoriamente durante el (prime time) del sábado en la noche 5 vieran canal 12, 2 canal 10 y 1 canal 3.

```
#help(Distributions)
```

```
dmultinom(x=c(5,2,1), size = 8,  
prob=c(0.50,0.30,0.20), log = FALSE)
```

```
## [1] 0.0945
```

Ejemplo 5

Una empresa lechera desea conocer la opinión que se tiene sobre sus tres productos estrella, yogurt light, queso crema y helado de yogurt. Las preferencias a cerca de los productos son del 10%, 30% y 40% respectivamente. ¿Cuál es la probabilidad de que en una muestra aleatoria de 10 personas tres prefieran el yogurt light, dos prefieran el queso crema y tres el helado de yogurt?

```
dmultinom(x=c(3, 2, 3, 10-3-2-3), size = 10,  
prob=c(0.10, 0.30, 0.40, 0.20), log = FALSE)
```

```
## [1] 0.00580608
```

Ejemplo 6 (Como ejercicio) (Hernández, 2008, p. 137)

En un hogar viven 4 adultos: 2 están con el candidato A, uno con el candidato B y uno con el candidato C. Se selecciona una muestra con reemplazo de tres personas y se anotan los nombres de los candidatos que apoyan, sea X_1 : el número de veces que sale A, X_2 : el número de veces que sale B y X_3 : el número de veces que sale C. ¿Cuál es la probabilidad conjunta de X_1 , X_2 y X_3 ?

Teoremas relativos a la distribución multinomial

Si las variables $X_1, X_2, \dots, X_k$ se distribuyen como una multinomial de parámetros n y $p_1, p_2, \dots, p_k$, entonces:

- 1 La distribución de probabilidad marginal de X_i es binomial de parámetros n y p_i .
- 2 La distribución de probabilidad de $X_i + X_j$, $i \neq j$, es binomial de parámetros n y $(p_i + p_j)$.
- 3 La distribución condicional de X_i dado $X_j = x_j$, $i \neq j$, es binomial de parámetros $n - x_j$ y $\frac{p_i}{1 - p_j}$

Teoremas relativos a la distribución multinomial

- 4 $Cov(X_i X_j) = -np_i p_j$ para $i \neq j$.
- 5 La generatriz de momentos conjunta de una variable aleatoria multinomial $X = X_1, X_2, \dots, X_k$ es:

$$M_{X_1, X_2, \dots, X_k}(t_1, t_2, \dots, t_k) = (p_1 \cdot e^{t_1} + p_2 \cdot e^{t_2} + \dots + p_k \cdot e^{t_k})^n$$

Prueba 1)

Considere un experimento aleatorio que puede producir k diferentes resultados denotados por $s_1, s_2, \dots, s_k$ con probabilidades respectivas $p_1, p_2, \dots, p_k$ y cuya suma es 1. Suponga que el experimento se repite n veces, de manera que los eventos son mutuamente independientes. Sea X_i el número de veces que ocurre el resultado s_i en las n repeticiones, con $X_i = 0, 1, \dots, n$ y $\mathbb{P}(s_i) = p_i$ en cada repetición. Por tanto, X_i es una variable con distribución binomial de parámetros n y p_i , es decir, $X_i \sim \text{Bin}(n, p_i)$.

Prueba 2)

Sea $Y = X_i + X_j$. Y es el número de veces que ocurre s_i o s_j en las n repeticiones del experimento, con $\mathbb{P}(s_i \text{ o } s_j) = p_i + p_j$ en cada repetición. Por tanto, Y se distribuye como una binomial de parámetros n y $p_i + p_j$, es decir, $Y \sim \text{Bin}(n, p_i + p_j)$.

Prueba 3)

Tómese el caso $i = 1, j = 2$. Sea $y = n - X_1 - X_2$. Las variables X_1, X_2, Y se distribuyen como una multinomial de parámetros n, p_1, p_2 y $1 - p_1 - p_2$. Esto sucede por que en cada repetición del experimento solo se consideran tres resultados posibles a saber s_1, s_2 y todos los demás $(s_3, s_4, \dots, s_k)$ con probabilidades p_1, p_2 y $1 - p_1 - p_2$, respectivamente. Tenemos que:

Prueba 3)

$$\begin{aligned}\mathbb{P}(X_1 = x_1 | X_2 = x_2) &= \frac{\mathbb{P}(X_1 = x_1, X_2 = x_2)}{\mathbb{P}(X_2 = x_2)} \\&= \frac{\mathbb{P}(X_1 = x_1, Y = n - x_1 - x_2)}{\mathbb{P}(X_2 = x_2)} = \frac{\frac{n! \cdot p_1^{x_1} p_2^{x_2} (1 - p_1 - p_2)^{n-x_1-x_2}}{x_1! x_2! (n - x_1 - x_2)!}}{\frac{n! \cdot p_2^{x_2} (1 - p_2)^{n-x_2}}{x_2! (n - x_2)!}} \\&= \frac{(n - x_2)! \cdot p_1^{x_1} (1 - p_1 - p_2)^{n-x_1-x_2}}{(1 - p_2)^{n-x_2} \cdot x_1! (n - x_1 - x_2)!} \\&= \frac{(n - x_2)! \cdot p_1^{x_1} (1 - p_1 - p_2)^{n-x_2} \cdot (1 - p_1 - p_2)^{-x_1}}{x_1! \cdot (n - x_1 - x_2)! (1 - p_2)^{n-x_2}} \\&= \frac{\binom{n - x_2}{x_1} \cdot p_1^{x_1} \cdot 1 \cdot (1 - p_1 - p_2)^{n-x_2}}{(1 - p_1 - p_2)^{x_1} \cdot (1 - p_2)^{n-x_2}}\end{aligned}$$

Prueba 3)

$$\begin{aligned} &= \frac{\binom{n-x_2}{x_1} \cdot p_1^{x_1} \cdot (1-p_2)^{x_1} \cdot (1-p_1-p_2)^{n-x_2}}{(1-p_2)^{x_1} \cdot (1-p_1-p_2)^{x_1} \cdot (1-p_2)^{n-x_2}} \\ &= \binom{n-x_2}{x_1} \cdot \left(\frac{p_1}{1-p_2}\right)^{x_1} \cdot (1-p_1-p_2)^{n-x_1-x_2} \frac{1}{(1-p_2)^{n-x_1-x_2}} \\ &= \binom{n-x_2}{x_1} \cdot \left(\frac{p_1}{1-p_2}\right)^{x_1} \cdot \left(\frac{1-p_1-p_2}{1-p_2}\right)^{n-x_1-x_2} \\ &= \binom{n-x_2}{x_1} \cdot \left(\frac{p_1}{1-p_2}\right)^{x_1} \cdot \left(1 - \frac{p_1}{1-p_2}\right)^{n-x_1-x_2} \end{aligned}$$

que es una binomial con parámetros $n - x_2$ y $\frac{p_1}{1-p_2}$, es decir,

$$\mathbb{P}(X_1 = x_1 | X_2 = x_2) \sim \text{Bin} \left(n - x_2, p = \frac{p_1}{1-p_2} \right)$$

Prueba 4)

Como $X_i + X_j$ es una binomial de parámetros n y $p_i + p_j$ como se probó en (2) y, asimismo X_i es una binomial de parámetros n y p_i , análogamente X_j es una binomial de parámetros n y p_j . Recordemos que, si $X \sim \text{Bin}(n, p)$ entonces $\text{Var}(X) = np(1-p)$. Además, $\text{Var}(X_i + X_j) = \text{Var}(X_i) + \text{Var}(X_j) + 2\text{Cov}(X_i, X_j)$.

De esta forma tenemos que:

$$\begin{aligned}\text{Var}(X_i + X_j) &= n(p_i + p_j)[1 - (p_i + p_j)] \\ &= n(p_i + p_j) - n(p_i + p_j)^2 \\ &= np_i + np_j - n(p_i^2 + 2p_i p_j + p_j^2) \\ &= np_i + np_j - np_i^2 - 2np_i p_j - np_j^2\end{aligned}$$

Prueba 4)

Por otra parte

$$\text{Var}(X_i + X_j) = \text{Var}(X_i) + \text{Var}(X_j) + 2\text{Cov}(X_i, X_j)$$

$$= np_i(1 - p_i) + np_j(1 - p_j) + 2\text{Cov}(X_i, X_j)$$

$$= np_i - np_i^2 + np_j - np_j^2 + 2\text{Cov}(X_i, X_j)$$

Igualando las dos expresiones de $\text{Var}(X_i + X_j)$ tenemos que

$$\text{Var}(X_i + X_j) = \text{Var}(X_i + X_j)$$

$$np_i - np_i^2 + np_j - np_j^2 + 2\text{Cov}(X_i, X_j) = np_i + np_j - np_i^2 - 2np_i p_j - np_j^2$$

$$2\text{Cov}(X_i, X_j) = -2np_i p_j$$

$$\text{Cov}(X_i, X_j) = -np_i p_j$$

Prueba 5)

$$M_{X_1, X_2, \dots, X_k}(t_1, t_2, \dots, t_k)$$

$$E(e^{t_1 x_1 + \dots + t_k x_k})$$

$$= \sum_{R_{X_1}} \dots \sum_{R_{X_k}} e^{t_1 x_1 + \dots + t_k x_k} \frac{n!}{x_1! \dots x_k!} p_1^{x_1} \dots p_k^{x_k}$$

$$= \sum_{R_{X_1}} \dots \sum_{R_{X_k}} \frac{n!}{x_1! \dots x_k!} (p_1 e^{t_1})^{x_1} \dots p_k (p_1 e^{t_1})^{x_k}$$

Por el teorema del multinomio

$$= (p_1 \cdot e^{t_1} + p_2 \cdot e^{t_2} + \dots + p_k \cdot e^{t_k})^n$$

Ejemplo 7

Suponga que para las variables aleatorias X_1, X_2, X_3 se tiene que $E(X_1) = 4$,

$E(X_2) = 9, E(X_3) = 3, \text{Var}(X_1) = 3, \text{Var}(X_2) = 7, \text{Var}(X_3) = 5, \text{Cov}(X_1, X_2) = 1, \text{Cov}(X_2, X_3) = -2, \text{Cov}(X_1, X_3) = -3$.

Además sea $Y = 2X_1 - 3X_2 + 4X_3, Z = X_1 + 2X_2 - X_3$.

Calcule los siguientes valores esperados

- a) $E(Y)$
- b) $\text{Var}(Y)$
- c) $\text{Cov}(Y, Z)$
- d) Repita el ejercicio, pero asumiendo que X_1, X_2, X_3 son variables aleatorias de una distribución multinomial con parámetros $M(n = 20, p_{x_1} = 0.35, p_{x_2} = 0.15, p_{x_3} = 0.50)$

Referencias I

Hernández, Ó. (2008). *Modelos probabilísticos discretos*. Editorial UCR.

Miller, I., & Miller, M. (2004). *Mathematical statistics with applications*. Prentice Hall.