Preguntas teóricas de Regresión Lineal

Forro — Examen No. 2 / Segundo semestre 2026

Víctor Brizuela · Escuela de Estadística, Universidad de Costa Rica

Contenido

1. Comparación de modelos y verosimilitud **1**

1.1. ¿Qué hipótesis se prueba al comparar modelos anidados? . . . 1
1.2. ¿Cuándo es equivalente la prueba t a la prueba F? . . . 2
1.3. ¿Se puede comparar con el `summary` dos modelos que difieren en dos o más coeficientes? . . . 2
1.4. Si SCRes del modelo A es mayor que la del B, ¿cuál tiene mayor verosimilitud? . . . 2
1.5. Si A tiene 3 variables y B tiene 5, ¿cuál tiene mayor AIC? . . . 2
1.6. ¿Para qué se suma una cantidad en el AIC o el BIC? . . . 2

2. Selección de variables **3**

2.1. ¿Cuál es la diferencia entre el R^2 y el R^2 ajustado? ¿Qué problema tiene usar R^2 para comparar modelos? . . . 3
2.2. ¿Cuál es la diferencia entre el R^2 ajustado y el R^2 parcial? . . . 3
2.3. ¿En qué consiste el PRESS y por qué mide poder predictivo? . . . 4
2.4. ¿Por qué es preferible P^2 a R^2 al seleccionar modelos? . . . 4
2.5. ¿Cuándo se detiene la selección hacia atrás? . . . 4
2.6. ¿Por qué no aparece un factor en la salida de `drop1`? . . . 4
2.7. ¿Cómo se sabe si un modelo es sesgado? . . . 5

3. Interacción y predictores categóricos **5**

3.1. ¿Cómo se interpreta el gráfico de rectas por grupo respecto a la interacción? . . . 5
3.2. ¿Cómo se escribe la hipótesis de interacción y qué se está contrastando? . . . 6
3.3. ¿Se pueden unir dos categorías de un factor en una sola? . . . 8

4. Influencia y diagnósticos **8**

4.1. ¿Cuánto debe dar la distancia de Cook para considerar influencia? . . . 8
4.2. ¿Cómo se interpretan los gráficos de regresión parcial? . . . 8
4.3. ¿Qué problema genera la multicolinealidad? . . . 9

1. Comparación de modelos y verosimilitud

1.1 ¿Qué hipótesis se prueba al comparar modelos anidados?

Con palabras: los predictores extra que tiene el modelo grande frente al pequeño no aportan nada adicional para explicar la variabilidad de la variable respuesta, una vez que están los del modelo pequeño.

Formalmente: H_0: los coeficientes de esos predictores adicionales son todos cero; H_1: al menos uno es

distinto de cero. Se prueba con

$$F = \frac{(\text{SCRes}_{\text{peq}} - \text{SCRes}_{\text{gde}})/q}{\text{CMRes}_{\text{gde}}} \sim F_{q,\, n-p_{\text{gde}}}.$$

Si se rechaza H_0 se prefiere el modelo grande; si no, el pequeño por parsimonia. Si lo que se prueba es una interacción, la hipótesis en términos de los datos es que las rectas de todos los grupos son paralelas.

1.2 ¿Cuándo es equivalente la prueba t a la prueba F?

Cuando la diferencia entre el modelo grande y el pequeño es solamente **un predictor**, es decir, cuando la hipótesis se plantea para un solo β. En ese caso la F tiene 1 grado de libertad en el numerador, $F = t^2$, y la probabilidad asociada al estadístico F es la misma que la del estadístico t.

La razón

Si $T \sim t_m$, entonces $T^2 \sim F_{1,m}$; y como la prueba t es bilateral, $P(|T| > |t|) = P(F > t^2)$. Por eso cada línea del `summary` equivale a comparar el modelo contra el mismo sin esa variable. No son equivalentes cuando se prueban dos o más coeficientes a la vez, por ejemplo con un factor de más de dos categorías o con su interacción.

1.3 ¿Se puede comparar con el `summary` dos modelos que difieren en dos o más coeficientes?

No. Cada t del `summary` prueba un coeficiente con todos los demás presentes; para probar que dos o más son cero simultáneamente se necesita la F con q grados de libertad en el numerador. Pasa lo mismo con un factor de más de dos categorías o con su interacción.

1.4 Si SCRes del modelo A es mayor que la del B, ¿cuál tiene mayor verosimilitud?

El **B**. Con $\hat{\sigma}^2 = \text{SCRes}/n$,

$$\log L = -\frac{n}{2}\log\left(2\pi\hat{\sigma}^2\right) - \frac{n}{2},$$

que decrece con SCRes. Menor SCRes implica mayor verosimilitud. Por la misma razón, el modelo más grande de un par anidado siempre tiene verosimilitud igual o mayor.

1.5 Si A tiene 3 variables y B tiene 5, ¿cuál tiene mayor AIC?

No se puede saber sin los valores. B tiene mejor verosimilitud (su deviancia es menor), pero paga una multa de $2 \cdot 2 = 4$ unidades más. Tendrá mayor AIC si la mejora en $-2\log L$ es menor que 4. Hay que calcular ambos y comparar.

1.6 ¿Para qué se suma una cantidad en el AIC o el BIC?

$$\text{AIC} = -2\log L + 2k, \qquad \text{BIC} = -2\log L + k\log n$$

Para **penalizar la complejidad**. La deviancia $-2\log L$ siempre baja al agregar parámetros, así que sola siempre elegiría el modelo más grande. El término $2k$ (o $k\log n$) cobra cada parámetro, para que solo se acepte uno nuevo si mejora el ajuste más de lo que cuesta. Es el equilibrio entre ajuste y parsimonia.

2. Selección de variables

2.1 ¿Cuál es la diferencia entre el R^2 y el R^2 ajustado? ¿Qué problema tiene usar R^2 para comparar modelos?

La SCRes siempre decrece al agregar predictores, a veces tan poco que no se nota. Como la SCT no varía, el $R^2 = 1 - \text{SCRes/SCT}$ siempre aumenta, aunque la variable no sirva. Por eso, si se usara el R^2 para comparar modelos con distinto número de variables, siempre se elegiría el más grande.

El R^2 ajustado penaliza los predictores irrelevantes, porque divide cada suma entre sus grados de libertad:

$$R^2_{aj} = 1 - \frac{\text{SCRes}/(n-p)}{\text{SCT}/(n-1)}.$$

Si una variable reduce SCRes menos de lo que cuesta perder un grado de libertad, el R^2 ajustado baja.

Idea clave

El R^2 sirve para **describir** un modelo: es la proporción de la variabilidad de la respuesta que explican *las variables incluidas en el modelo*, no una medida de qué tan bueno es el modelo. El R^2 ajustado sirve para **comparar** modelos de distinto tamaño.

2.2 ¿Cuál es la diferencia entre el R^2 ajustado y el R^2 parcial?

El R^2 ajustado se refiere a un **modelo completo** y sirve para comparar modelos de distinto tamaño. El R^2 parcial se refiere a **una variable dentro de un modelo** y mide su aporte marginal.

El R^2 ajustado corrige el R^2 por la cantidad de predictores (fórmula de la pregunta anterior). Al agregar una variable, SCRes baja, pero $n-p$ también; si la variable aporta poco, CMRes sube y el R^2 ajustado baja. Por eso se elige el modelo con mayor R^2 ajustado. Su denominador es siempre la variabilidad total de Y.

El R^2 parcial mide qué proporción de lo que todavía no estaba explicado logra explicar una variable cuando entra después de las demás:

$$R^2_{\text{parcial}} = \frac{\text{SCRes}_{\text{sin } x_j} - \text{SCRes}_{\text{con } x_j}}{\text{SCRes}_{\text{sin } x_j}}.$$

La diferencia clave está en el denominador: no es la SCT, sino la SCRes del modelo sin la variable, es decir, lo que quedaba pendiente.

	R^2 **ajustado**	R^2 **parcial**
A qué se refiere	Un modelo completo	Una variable dado el resto
Denominador	Variabilidad total (corregida por gl)	SCRes del modelo sin esa variable
Para qué sirve	Comparar y elegir modelos	Medir el aporte marginal de una variable
Se relaciona con	`leaps`, selección de variables	SC marginal, prueba F, `avPlots`

Ejemplo con la base vida

El modelo completo tiene $R^2 = 0.764$ y $R^2_{aj} = 0.754$: las 8 variables explican el 76.4 % de la variabilidad de la esperanza de vida, y al cobrarles los 8 parámetros queda en 75.4 %. El R^2 parcial de `fecun` es $675.88/3124.25 = 0.216$: de la variabilidad que dejaban sin explicar las otras 7 variables, la fecundidad explica el 21.6 %.

El R^2 parcial es lo que se ve en el gráfico de regresión parcial: cuanto más apretados están los puntos alrededor de la recta en `avPlots`, más alto es el R^2 parcial de esa variable.

2.3 ¿En qué consiste el PRESS y por qué mide poder predictivo?

El PRESS es la suma de los cuadrados de los errores de predicción, donde cada observación se predice con el modelo ajustado sin ella:

$$\text{PRESS} = \sum_{i=1}^{n} \left(y_i - \hat{y}_{i(i)}\right)^2 = \sum_{i=1}^{n} \left(\frac{r_i}{1 - h_{ii}}\right)^2.$$

Es un buen indicador del poder predictivo porque mide qué tan bien predice el modelo datos que no usó para ajustarse, que es la situación real al predecir casos nuevos. Los residuos ordinarios, en cambio, se calculan con los mismos datos del ajuste y subestiman el error de predicción: un modelo sobreajustado tiene residuos pequeños pero predice mal casos nuevos, y su PRESS lo pone en evidencia. Entre dos modelos se prefiere el de **menor PRESS** (o mayor P^2).

2.4 ¿Por qué es preferible P^2 a R^2 al seleccionar modelos?

Porque

$$P^2 = 1 - \frac{\text{PRESS}}{\text{SCT}_i}, \qquad \text{SCT}_i = \left(\frac{n}{n-1}\right)^2 \text{SCT},$$

se basa en predicciones fuera de la muestra y no aumenta automáticamente con más variables. Una variable irrelevante empeora las predicciones y baja el P^2, mientras que el R^2 sube igual.

2.5 ¿Cuándo se detiene la selección hacia atrás?

- **Con la prueba F:** cuando ningún predictor que queda tiene un valor de p mayor que el α definido (por ejemplo 0.05 o 0.15): todos son significativos y no se elimina ninguno más.
- **Con AIC (o BIC):** cuando quitar cualquiera de los términos que quedan aumenta el AIC respecto al modelo actual, es decir, cuando la fila `<none>` de `drop1` tiene el AIC más bajo.

En ambos casos se respeta la jerarquía: no se eliminan variables que formen parte de una interacción que sigue en el modelo. Al terminar hay que justificar por qué se detuvo el proceso.

2.6 ¿Por qué no aparece un factor en la salida de `drop1`?

Porque está en una interacción que sigue en el modelo. Por el principio de jerarquía, `drop1` solo ofrece quitar términos que no forman parte de un término de mayor orden. Primero hay que evaluar la interacción.

2.7 ¿Cómo se sabe si un modelo es sesgado?

Con la C_p de Mallows, usando el CMRes del modelo más completo como estimador de σ^2:

$$C_p = \frac{\text{SCRes}_p}{\text{CMRes}_{\text{completo}}} - (n - 2p).$$

Si $C_p \approx p$ o es menor, no hay evidencia de sesgo. Si C_p es claramente mayor que p, al modelo le faltan términos importantes, porque su SCRes contiene sesgo además de error.

3. Interacción y predictores categóricos

3.1 ¿Cómo se interpreta el gráfico de rectas por grupo respecto a la interacción?

Es el gráfico `xyplot(y ~ x, groups = f, type = c("p","r"))`. Toda respuesta sigue esta estructura:

1. Describir la pendiente de cada grupo (dirección e inclinación).

2. Comparar las rectas: si son paralelas, si se acercan, se alejan o se cruzan.

3. Decir qué se sospecha sobre la interacción en términos de los datos.

4. Aclarar que debe confirmarse con una prueba formal.

5. Si aplica, comentar cuántos datos tiene cada grupo o qué rango de x cubre.

En las plantillas, [Y] es la respuesta, [X] el predictor numérico y [grupo] las categorías del factor.

Caso 1: todas las rectas son aproximadamente paralelas

"Las rectas de todas las categorías de [factor] tienen pendientes muy similares, es decir, son aproximadamente paralelas. Esto indica que al aumentar [X], el [Y] promedio [aumenta/disminuye] a un ritmo parecido en todos los grupos; lo que cambia entre ellos es el nivel (el intercepto), no la pendiente. Por lo tanto, no se espera interacción entre [X] y [factor]. Esto debe confirmarse con la prueba de hipótesis de no interacción."

Caso 2: pendientes claramente distintas y las rectas se cruzan

"Las rectas tienen pendientes claramente distintas: en [grupo A] la pendiente es [positiva/negativa y pronunciada], mientras que en [grupo B] es [más suave/casi horizontal/de signo contrario]. Las rectas se cruzan alrededor de [X] $\approx$ [valor], de modo que para valores bajos de [X] el [Y] promedio es mayor en [grupo], y para valores altos es mayor en [otro grupo]. Como el efecto de [X] sobre [Y] depende de la categoría de [factor], se puede sospechar que hay interacción. Esto debe confirmarse con una prueba de hipótesis formal."

Caso 3: varias rectas paralelas y una distinta

"Las rectas de [grupos A y B] son prácticamente paralelas [y casi horizontales], mientras que la recta de [grupo C] tiene una pendiente muy distinta ([más pronunciada/de signo contrario]). Es decir, el efecto de [X] sobre el [Y] promedio parece ser similar en [A y B], pero diferente en [C]. Se puede sospechar que hay interacción entre [X] y [factor], principalmente por el comportamiento de [C]. Esto debe confirmarse con una prueba formal. Además, podría evaluarse si [A y B] comparten la misma pendiente."

Caso 4: no se cruzan, pero se acercan o se separan

"Las rectas no se cruzan en el rango observado de [X], pero no son paralelas: [se van separando/se van acercando] conforme aumenta [X]. Esto significa que la diferencia en el [Y] promedio entre [grupo A] y [grupo B] no es constante, sino que [aumenta/disminuye] con [X]. Se puede sospechar interacción entre [X] y [factor], aunque menos marcada que si las rectas se cruzaran. Debe confirmarse con la prueba formal."

Caso 5: pendientes con signo contrario

"En [grupo A] el [Y] promedio aumenta al aumentar [X], mientras que en [grupo B] disminuye. Como el efecto de [X] cambia incluso de dirección según la categoría de [factor], se puede sospechar una interacción fuerte. Esto debe confirmarse con una prueba de hipótesis formal."

Caso 6: diferencias poco claras

"Las pendientes de las rectas son algo distintas, pero las diferencias son pequeñas en relación con la dispersión de los puntos alrededor de cada recta. A partir del gráfico no es claro si existe interacción entre [X] y [factor]; podría tratarse de variación aleatoria. Se requiere la prueba formal para decidirlo."

Comentarios que se agregan cuando aplican

- **Pocos datos en un grupo:** "Las categorías [A y B] tienen pocas observaciones, por lo que sus pendientes se estiman con poca precisión y las diferencias observadas podrían deberse al azar."
- **Rango de x distinto:** "Los datos de [grupo] solo cubren valores de [X] entre [a] y [b], por lo que su recta no debe extrapolarse fuera de ese rango; conviene comparar los grupos solo donde se traslapan."
- **Respuesta en logaritmo:** "Como la respuesta está en logaritmo, una diferencia en las pendientes significa que el cambio porcentual en [Y] al aumentar [X] es distinto entre los grupos."

Qué evitar

- Afirmar "hay interacción" solo con el gráfico. Se dice "se puede sospechar" o "se espera", y que debe confirmarse con la prueba (en la rúbrica del 2023 eso costaba puntos).
- Confundir rectas a distinta altura con interacción: eso es diferencia de interceptos. La interacción es que las **pendientes** sean distintas.
- Quedarse en lo visual: hay que traducirlo a los datos, "el efecto de [X] sobre [Y] depende de [factor]".

3.2 ¿Cómo se escribe la hipótesis de interacción y qué se está contrastando?

Forma matemática. Se parte del modelo con interacción. Con un predictor numérico X y un factor de k categorías (indicadoras $I_2, \ldots, I_k$):

$$\mu_{Y|X,I} = \beta_0 + \beta_1 X + \gamma_2 I_2 + \cdots + \gamma_k I_k + \delta_2 X I_2 + \cdots + \delta_k X I_k$$

Los δ son los coeficientes de interacción: cada uno es la diferencia entre la pendiente de ese grupo y la de la referencia.

$$H_0: \ \delta_2 = \delta_3 = \cdots = \delta_k = 0 \qquad\qquad H_1: \ \text{al menos un } \delta_j \neq 0$$

Qué se está contrastando. Dos maneras de describir la relación: una donde el efecto de X es el mismo en todos los grupos y otra donde depende del grupo. Se puede decir de tres formas equivalentes:

	H_0 **(no hay interacción)**	H_1 **(hay interacción)**
Rectas	Las rectas poblacionales de todos los grupos son paralelas (misma pendiente, distinto intercepto)	Al menos una recta tiene pendiente distinta
Efecto de X	El cambio en el Y promedio al aumentar X es el mismo en todas las categorías	Ese cambio depende de la categoría
Modelos	El modelo sin interacción explica lo mismo que el modelo con interacción	El modelo con interacción explica significativamente más

Son lo mismo porque si todos los δ son cero, todos los grupos tienen la pendiente β_1 y quitar esos términos no cambia el ajuste.

Cómo se prueba. Es una comparación de modelos anidados: `anova(mod_sin, mod_con)`, con `mod_con = lm(y ~ x*f)` y `mod_sin = lm(y ~ x + f)`. El estadístico es

$$F = \frac{(\text{SCRes}_{\text{sin}} - \text{SCRes}_{\text{con}})/(k-1)}{\text{CMRes}_{\text{con}}}.$$

Con 2 categorías, la t del `summary` para la interacción da la misma prueba.

Planteamiento de la hipótesis

"Se contrasta si existe interacción entre [X] y [factor]. H_0: no hay interacción, es decir, las rectas poblacionales de todas las categorías de [factor] son paralelas y el efecto de [X] sobre el [Y] promedio es el mismo en todos los grupos; el modelo sin interacción explica lo mismo que el modelo con interacción. H_1: el efecto de [X] sobre el [Y] promedio depende de la categoría de [factor]; al menos una recta tiene una pendiente distinta."

Respuesta si se rechaza H_0

"Se obtuvo $F =$ [valor] con $[k-1]$ y $[n-p]$ grados de libertad. El numerador tiene $[k-1]$ grados de libertad porque se está probando que los $[k-1]$ coeficientes de interacción $([\delta_2, \ldots, \delta_k])$ son cero, y el denominador tiene $[n-p]$ porque hay $[n]$ datos y el modelo con interacción tiene $[p]$ coeficientes. Como la probabilidad asociada es $[p]$, menor que 0.05, se rechaza la hipótesis nula: hay evidencia de interacción entre [X] y [factor], es decir, el aumento en el [Y] promedio al aumentar [X] no es el mismo en todas las categorías de [factor] y las rectas no son paralelas, por lo que se trabaja con el modelo con interacción."

Respuesta si no se rechaza H_0

"Se obtuvo $F =$ [valor] con $[k-1]$ y $[n-p]$ grados de libertad. El numerador tiene $[k-1]$ grados de libertad porque se está probando que los $[k-1]$ coeficientes de interacción $([\delta_2, \ldots, \delta_k])$ son cero, y el denominador tiene $[n-p]$ porque hay $[n]$ datos y el modelo con interacción tiene $[p]$ coeficientes. Como la probabilidad asociada es $[p]$, mayor que 0.05, no se rechaza la hipótesis nula: no hay evidencia de interacción entre [X] y [factor], por lo que se puede asumir que el aumento en el [Y] promedio al aumentar [X] es el mismo en todas las categorías y que las rectas son paralelas; se usa el modelo sin interacción por parsimonia."

3.3 ¿Se pueden unir dos categorías de un factor en una sola?

Unir dos categorías significa suponer que tienen **la misma recta**. Lo que hay que probar depende de si hay interacción.

Respuesta sin interacción

"Como no hay interacción, las categorías tienen la misma pendiente, así que unir [A] y [B] solo requiere que tengan el mismo intercepto (H_0: $\lambda_j = 0$). En el `summary`, el coeficiente de [B] tiene una probabilidad de [p], [mayor/menor] que 0.05, por lo que [no hay evidencia de diferencia en el [Y] promedio entre [A] y [B] para un mismo [X] y sí se pueden unir / el [Y] promedio difiere entre [A] y [B] para un mismo [X] y no se deben unir]."

Respuesta con interacción

"Para unir [A] y [B] deben tener la misma recta (H_0: $\lambda_j = \delta_j = 0$). Comparando el modelo con ambas categorías unidas contra el original se obtuvo $F =$ [valor] con 2 y $[n - p]$ grados de libertad y probabilidad [p], por lo que [no se rechaza H_0 y se pueden unir / se rechaza H_0 y no se deben unir, porque difieren en el nivel o en su relación con [X]]."

4. Influencia y diagnósticos

4.1 ¿Cuánto debe dar la distancia de Cook para considerar influencia?

Se compara con la distribución $F(p,\, n - p)$:

Percentil de D_i en $F(p, n-p)$	**Influencia sobre el ajuste en general**
Por debajo de 0.10 o 0.20	**Poca**
Entre 0.20 y 0.50	**Media**
Cerca de 0.50 o más	**Fuerte**

4.2 ¿Cómo se interpretan los gráficos de regresión parcial?

El eje Y tiene los residuos de regresar Y sobre los demás predictores (lo que falta por explicar). El eje X tiene los residuos de regresar x_j sobre esos mismos predictores (la información nueva de x_j). Se revisan cuatro cosas:

1. **La pendiente de la recta.** Es exactamente $\hat{\beta}_j$ del modelo completo (teorema de Frisch–Waugh–Lovell). El signo da la dirección del efecto con los demás predictores fijos, y la inclinación da la magnitud. Una recta casi horizontal significa que x_j no aporta después de los otros; su prueba t en el `summary` tampoco será significativa.
2. **Qué tan apretados están los puntos alrededor de la recta.** Mide la fuerza del aporte marginal. Una nube estrecha alrededor de una recta inclinada significa que x_j explica bastante de lo que quedaba pendiente (R^2 parcial alto). Una nube muy dispersa con poca pendiente significa un aporte débil aunque el coeficiente no sea cero.
3. **Qué tan ancho es el rango del eje X.** Si los residuos de x_j quedan concentrados cerca de cero, a x_j le queda poca información propia porque los demás predictores casi la reproducen. Eso es multicolinealidad: el coeficiente se estima con poca precisión (error estándar grande, VIF alto).

4. **Los puntos que quedan lejos de los demás.** Un punto en un extremo del eje X y fuera de la tendencia puede estar jalando la pendiente: es influyente sobre $\hat{\beta}_j$ en particular (lo mismo que mide su DFBETAS). `avPlots` etiqueta los casos más extremos. Si la recta depende de uno o dos puntos, se reajusta sin ellos y se compara el coeficiente.

4.3 ¿Qué problema genera la multicolinealidad?

Infla la varianza de los coeficientes en un factor

$$\text{VIF}_j = \frac{1}{1 - R_j^2}.$$

Los coeficientes quedan imprecisos e inestables (cambian mucho al agregar o quitar una variable o un dato), pueden tener el signo contrario al esperado y variables importantes pueden salir no significativas. Las predicciones dentro del rango de los datos no se afectan tanto; el problema es interpretar los coeficientes individuales.