

Resumen: modelos de regresión aplicados

Materia del primer examen parcial

Kendall Martínez

Índice

1. Motivación: ¿por qué condicionar?	2
2. El modelo de regresión lineal	3
2.1. Modelo para la media y modelo para la respuesta	3
2.2. Varios predictores	4
2.3. Linealidad	5
2.4. Supuestos del modelo	5
3. Estimación de los coeficientes	7
3.1. Notación matricial	7
3.2. Mínimos cuadrados ordinarios	7
3.3. Máxima verosimilitud	8
3.4. Valor ajustado en un punto	8
4. Interpretación de los coeficientes	9
4.1. El coeficiente como efecto parcial	9
4.2. Un aumento que tenga sentido	9
4.3. Alcance del modelo	10
5. Correlación y coeficientes estandarizados	11
5.1. Correlación	11
5.2. El problema de las escalas	11
5.3. Cómo estandarizar	11
5.4. Cuál predictor tiene mayor impacto	12
5.5. Volver a las unidades originales	13
6. La variabilidad de las estimaciones	13
6.1. Estimación de la varianza condicional: el CMRes	14
6.2. Varianza de los coeficientes	14
6.3. Errores estándar	15
6.4. ¿Qué pasa si...?	16

7. Intervalos de confianza	16
7.1. Para un coeficiente	16
7.2. Para la media condicional	17
7.3. Para valores individuales	18
7.4. Comparación entre ambos intervalos	18
7.5. Flujo para construir un intervalo	20
8. Descomposición de la variabilidad	20
8.1. La suma de cuadrados total	20
8.2. La partición	20
8.3. Grados de libertad y tabla de análisis de varianza	21
8.4. Coeficiente de determinación	22
9. Aporte marginal y comparación de modelos anidados	22
9.1. Suma de cuadrados de regresión marginal	22
9.2. La tabla de análisis de varianza secuencial	23
9.3. Coeficiente de determinación parcial	23
9.4. Modelos anidados	24
9.5. La prueba F	24
9.6. Casos particulares	26
9.7. Errores al comparar modelos	27
9.8. Flujo para comparar modelos	27
10. Cómo reconstruir resultados con información parcial	27
11. Cómo redactar las interpretaciones	29
12. Preguntas conceptuales frecuentes	30
13. Puente con diseño de experimentos	32
14. Resumen de fórmulas clave	33
15. Videos de clase	35

1. Motivación: ¿por qué condicionar?

Cuando se analiza una variable respuesta Y por sí sola, toda su variabilidad queda mezclada en una única distribución: la que se debe a que otras variables X cambian de un individuo a otro, y la que existe entre individuos que comparten los mismos valores de X . Si no se separan ambas fuentes, no se puede describir ni predecir Y de forma útil.

La idea de la regresión es **condicionar**: para cada valor de x existe una distribución de valores de Y (la distribución condicional), y lo que interesa es cómo se desplaza el centro de esa distribución cuando cambia x .

Media condicional y media no condicional

- **Media condicional** $\mu_{Y|x}$: la media de Y entre todos los individuos que tienen un valor fijo x del predictor (o una combinación fija de valores si hay varios predictores). Es el centro de una subpoblación.
- **Media no condicional** μ_Y : la media de Y en toda la población, sin fijar ningún valor de los predictores. Se estima con $\bar{y}$.

Variabilidad total y variabilidad condicional

Hay dos varianzas que conviene no confundir:

- **Variabilidad total**: dispersión de todos los valores de Y alrededor de $\bar{y}$, estimada con s_Y^2 . No depende de ningún modelo.
- **Variabilidad condicional**: dispersión de Y entre individuos con los mismos valores de los predictores, denotada σ^2 . Depende de cuáles variables se usan para condicionar.

Si X es informativa, la variabilidad condicional es mucho menor que la total: al fijar x los individuos se parecen más entre sí. Si X no aporta nada, ambas son casi iguales.




Figura 1. Misma variabilidad total, distinta variabilidad condicional. En ambos paneles los valores de Y tienen exactamente la misma media (línea gris) y la misma desviación estándar (las líneas punteadas marcan $\bar{y} \pm 2s_Y$). En (a) los puntos se pegan a la recta: fijado x , queda poca dispersión. En (b) los puntos se alejan mucho de la recta: condicionar en X casi no reduce la variabilidad.

Cómo se construye cada situación

Para **reducir la variabilidad condicional sin cambiar la total**, los puntos se acercan a la recta pero se conserva el rango vertical de Y (se inclina más la nube). Para **reducir la variabilidad total sin cambiar la condicional**, se conserva la distancia de los puntos a la recta pero la recta se aplanan o el rango de X se acorta, de modo que las medias condicionales se separan menos entre sí.

2. El modelo de regresión lineal

2.1. Modelo para la media y modelo para la respuesta

El modelo de regresión lineal simple supone que la media condicional sigue una recta:

$$\mu_{Y|x} = \beta_0 + \beta_1 x, \quad (1)$$

donde β_0 es la media de Y cuando $x = 0$ y β_1 es el cambio en la media de Y cuando x aumenta una unidad. Como no todos los individuos de una subpoblación tienen el mismo valor de Y , se define el **error** como la distancia entre una observación y la media de su subpoblación, $\varepsilon = Y - \mu_{Y|x}$. Con eso, cada observación se escribe como

$$Y = \beta_0 + \beta_1 x + \varepsilon. \quad (2)$$

En la muestra se sustituye cada cantidad poblacional por su estimación:

Cantidad	Poblacional (desconocida)	Estimada (muestra)
Media condicional	$\mu_{Y x} = \beta_0 + \beta_1 x$	$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$
Distancia a la media	error $\varepsilon = Y - \mu_{Y x}$	residuo $r = Y - \hat{y}$
Observación	$Y = \mu_{Y x} + \varepsilon$	$Y = \hat{y} + r$
Varianza condicional	σ^2	CMRes

Dos reglas de notación que evitan la mayoría de errores de redacción:

- El modelo para la **media** nunca lleva error; el modelo para Y siempre lo lleva.
- El sombrero indica una estimación de una **media**: $\hat{y}$ no es el valor de un individuo, es el centro estimado de una subpoblación.

No es la Y la que aumenta β_1

Es incorrecto decir “si X aumenta una unidad, Y aumenta β_1 ”. Lo que aumenta β_1 es la **media** de Y . Dos individuos cuyos valores de x difieren en una unidad pueden tener cualquier par de valores de Y , incluso con el orden invertido, porque cada uno se ubica en cualquier punto de su propia distribución condicional.

2.2. Varios predictores

Con $p - 1$ predictores la media condicional es

$$\mu_{Y|x_1, \dots, x_{p-1}} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_{p-1} x_{p-1}, \quad (3)$$

con p coeficientes contando el intercepto. Cada β_j es un **efecto parcial**: el cambio en la media de Y cuando x_j aumenta una unidad, **manteniendo constantes los demás predictores**. Geométricamente, el conjunto de todas las medias condicionales es una recta con un predictor, un plano con dos y un hiperplano con tres o más.

El objetivo de agregar predictores es reducir la variabilidad condicional: al condicionar en una variable importante adicional, cada subpoblación se divide en subpoblaciones más homogéneas.

p cuenta coeficientes, no variables

Con predictores numéricos que entran una sola vez, p es el número de variables más uno. Deja de cumplirse con términos polinomiales, factores de tres o más niveles o interacciones, porque cada uno aporta más de un coeficiente.

2.3. Linealidad

Relación lineal

Hay relación lineal entre X y la media de Y cuando un aumento fijo en x produce siempre el **mismo cambio** en la media condicional, sin importar en qué parte del rango de x se haga el aumento. La linealidad se refiere a las **medias**, nunca a los valores individuales de Y .

No hay que confundirla con la **linealidad en los parámetros**, que es lo que hace lineal a un modelo: la media se escribe como combinación lineal de los β . Por eso $\mu_{Y|x} = \beta_0 + \beta_1 x + \beta_2 x^2$ describe una parábola y sigue siendo un modelo lineal.

Cómo verificarla gráficamente

Se hace un gráfico de dispersión de Y contra X con dos líneas superpuestas: la **recta de regresión**, que impone la forma lineal, y una **curva suavizada**, que sigue a las medias locales de los datos sin imponer ninguna forma.

- Si la curva suavizada se mantiene cerca de la recta en todo el rango, los datos apoyan la linealidad.
- Si la curva se separa de la recta de forma sistemática (por encima en los extremos y por debajo en el centro, o al revés), la media no cambia a ritmo constante y la recta subestima la media en unas regiones y la sobreestima en otras.




Figura 2. Verificación gráfica de la linealidad. En (a) la curva suavizada prácticamente coincide con la recta: la media aumenta a ritmo constante. En (b) la curva crece rápido al inicio y luego se aplana; la recta queda por encima de las medias en los extremos y por debajo en el centro.

2.4. Supuestos del modelo

El modelo clásico reúne los supuestos en un solo enunciado:

$$Y | x \sim N(\mu_{Y|x}, \sigma^2), \quad \text{con las observaciones independientes entre sí.} \quad (4)$$

Supuesto	Qué dice	Dónde se usa
Linealidad	$\mu_{Y x}$ es combinación lineal de los predictores tal como entran al modelo.	Toda interpretación de β_j y de $k\beta_j$. Sin ella, la recta se aparta sistemáticamente de las medias.
Normalidad	Para cada x , la distribución condicional de Y es normal.	En las distribuciones t y F de intervalos y pruebas, y en que máxima verosimilitud dé lo mismo que mínimos cuadrados.
Homocedasticidad	$V(Y x) = \sigma^2$ para todo x : el ancho de las distribuciones no cambia.	Permite usar un solo CMRes para toda combinación de predictores y escribir $V(\hat{\beta}) = \sigma^2(X'X)^{-1}$.
Independencia	El valor de Y de una observación no depende del de otra.	En la verosimilitud (producto de densidades) y en $V(\hat{\beta})$. No se verifica después: se garantiza con el diseño de recolección.




Figura 3. Los cuatro supuestos a la vez. Las medias (puntos negros) están sobre la recta (linealidad), cada distribución condicional es normal (normalidad) y todas tienen el mismo ancho (homocedasticidad).

Varianza condicional y varianza del error

Como $\varepsilon = Y - \mu_{Y|x}$ y $\mu_{Y|x}$ es una constante para x fijo, restarla solo recentra la distribución sin cambiar su dispersión:

$$V(Y | x) = V(\varepsilon) = \sigma^2, \quad \varepsilon \sim N(0, \sigma^2).$$

Por eso sí es correcto decir que la varianza condicional de la respuesta es la varianza

del error. El error tiene media cero porque $\mu_{Y|x}$ ya captura el centro.

3. Estimación de los coeficientes

3.1. Notación matricial

Con varios predictores se reúnen todas las observaciones en matrices. La **matriz de diseño** X tiene una fila por observación y una columna por coeficiente; su primera columna es de unos porque corresponde al intercepto:

$$X = \begin{bmatrix} 1 & x_{11} & \cdots & x_{1,p-1} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{n,p-1} \end{bmatrix}, \quad \hat{Y} = X\hat{\beta}, \quad \mathbf{r} = Y - \hat{Y}.$$

Conviene tener presentes las dimensiones, que se preguntan con frecuencia:

Objeto	Dimensión	Contenido
X	$n \times p$	columna de unos y valores de los predictores
$Y, \hat{Y}, \mathbf{r}$	$n \times 1$	respuestas, valores ajustados, residuos
$\hat{\beta}$	$p \times 1$	coeficientes estimados
$X'X, (X'X)^{-1}$	$p \times p$	información de los predictores
$\hat{V}(\hat{\beta})$	$p \times p$	varianzas y covarianzas de los coeficientes
x_h	$p \times 1$	valores de los predictores donde se estima la media
$\hat{y}_h = x_h' \hat{\beta}$	1×1	media condicional estimada en x_h

Por ejemplo, un modelo con 7 predictores tiene $p = 8$ coeficientes y su matriz $\hat{V}(\hat{\beta})$ es de 8×8 .

3.2. Mínimos cuadrados ordinarios

Se eligen los coeficientes que dejan los valores ajustados lo más cerca posible de los observados. Como los residuos positivos y negativos se cancelarían al sumarlos, se minimiza la suma de sus cuadrados:

$$\text{SCRes} = \sum_{i=1}^n r_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2. \quad (5)$$

La solución de ese problema de minimización es

$$\boxed{\hat{\beta} = (X'X)^{-1} X'Y} \quad (6)$$

siempre que $X'X$ sea invertible. En ese caso la solución es única: ningún otro vector de coeficientes produce una SCRes menor para esa muestra. Intuitivamente, $X'Y$ recoge cómo se relacionan los predictores con la respuesta y $(X'X)^{-1}$ corrige por cómo se distribuyen y relacionan los predictores entre sí.

3.3. Máxima verosimilitud

El otro camino busca los valores de los parámetros que hacen más creíbles los datos observados. La verosimilitud es el producto de las densidades de las observaciones (producto porque se asume independencia):

$$L(\theta) = \prod_{i=1}^n f(y_i | \theta). \quad (7)$$

Bajo normalidad, la estimación de σ^2 que maximiza L es SCRes/ n , y al sustituirla la log-verosimilitud queda, salvo constantes,

$$\log L = -\frac{n}{2} \log(\text{SCRes}). \quad (8)$$

Por qué MV y MCO dan los mismos coeficientes

Los coeficientes solo aparecen dentro de SCRes, y SCRes entra con signo negativo. Hacer $\log L$ lo más grande posible es lo mismo que hacer SCRes lo más pequeña posible, de modo que bajo normalidad ambos métodos producen $\hat{\beta} = (X'X)^{-1}X'Y$. La diferencia está en σ^2 : MV la estima con SCRes/ n , que es sesgada; por eso se usa CMRes = SCRes/ $(n - p)$.

3.4. Valor ajustado en un punto

Para estimar la media condicional en una combinación particular de valores de los predictores se arma el vector x_h , con un 1 en la primera posición (intercepto):

$$x_h = (1, x_{h1}, x_{h2}, \dots, x_{h,p-1})', \quad \hat{y}_h = x_h' \hat{\beta} = \hat{\beta}_0 + \hat{\beta}_1 x_{h1} + \dots + \hat{\beta}_{p-1} x_{h,p-1}. \quad (9)$$

El orden de x_h

Las entradas de x_h deben seguir **el mismo orden que los coeficientes** en $\hat{\beta}$, no el orden en que se describen las variables en un enunciado. Si la tabla de coeficientes lista altura, cantidad, grosor y longitud, el vector es $(1, \text{altura}, \text{cantidad}, \text{grosor}, \text{longitud})'$ aunque el texto haya mencionado las variables en otro orden.

Ejemplo: peso de tallos de caña

Con $\hat{\beta}_0 = -2.04$ y coeficientes 0.68 (altura, m), 0.02 (cantidad de entrenudos), 0.49 (grosor, cm) y -0.00004 (longitud del entrenudo, cm), para tallos de 2 m, 16 entrenudos,

3 cm de grosor y 10 cm de longitud:

$$x_h = (1, 2, 16, 3, 10)',$$
$$\hat{y}_h = -2.04 + 0.68(2) + 0.02(16) + 0.49(3) - 0.00004(10) = 1.11 \text{ kg.}$$

Se estima que los tallos con esas características tienen un peso **promedio** de 1.11 kg.

Dos propiedades permiten obtener valores ajustados sin volver a calcular todo:

La superficie pasa por las medias

En un modelo con intercepto, al evaluar todos los predictores en sus medias se obtiene la media de la respuesta:

$$\hat{y}(\bar{x}_1, \dots, \bar{x}_{p-1}) = \bar{y}.$$

La media esperada para un individuo “promedio” en todos los predictores es la media general de Y .

Además, como el cambio en la media es lineal, si se conoce $\hat{y}$ en un punto basta sumar los cambios: $\hat{y}(x') = \hat{y}(x) + \sum_j \hat{\beta}_j(x'_j - x_j)$. En regresión simple, $\hat{y}(x') = \hat{y}(x) + \hat{\beta}_1(x' - x)$.

4. Interpretación de los coeficientes

4.1. El coeficiente como efecto parcial

Si x_j aumenta k unidades, la media de Y cambia $k\beta_j$ unidades, manteniendo constantes los demás predictores. Por la linealidad, da igual dónde se haga el aumento: comparar subpoblaciones de 22 contra 27 años produce la misma diferencia de medias que comparar 30 contra 35.

Tres consecuencias que conviene tener claras:

- **El significado depende del modelo.** El coeficiente de un predictor en un modelo que incluye la edad compara subpoblaciones con la edad fija; en un modelo sin edad compara subpoblaciones que mezclan todas las edades. Por eso el valor cambia al quitar o agregar variables correlacionadas con él.
- **El valor depende de las unidades.** Si X_j se multiplica por c (por ejemplo, de centímetros a milímetros, $c = 10$), $\hat{\beta}_j$ se divide entre c . Los valores ajustados, los residuos y el ajuste son idénticos.
- **El intercepto rara vez se interpreta**, porque $x = 0$ suele quedar fuera del rango observado.

4.2. Un aumento que tenga sentido

Un aumento de una unidad puede no tener sentido práctico (un año, un centímetro). El criterio usual es interpretar el coeficiente para un aumento de alrededor de **una desviación**

estándar del predictor, porque representa una distancia típica dentro de los datos.

Paso 1. Revisar si el predictor tiene valores extremos (diagrama de caja).

Paso 2. Calcular s_{X_j} sin los valores extremos.

Paso 3. Tomar $k \approx s_{X_j}$, redondeado a una cantidad natural si se desea (9.66 años $\rightarrow$ 10 años).

Paso 4. Multiplicar por k el coeficiente (o los dos límites de su intervalo).

Paso 5. Redactar con “promedio”, “manteniendo constantes” y unidades (Sección 11).

Un valor extremo infla el aumento

Un solo valor extremo aumenta mucho la desviación estándar y hace que el “aumento con sentido” sea exagerado. En el estudio de caña, el intervalo para el coeficiente de altura es (0.53, 0.83). Con el extremo, $s = 0.52$ m y el peso promedio aumentaría entre 0.28 y 0.43 kg; sin él, $s = 0.35$ m y aumenta entre $0.53(0.35) = 0.19$ y $0.83(0.35) = 0.29$ kg. La segunda es la interpretación correcta.

4.3. Alcance del modelo

La ecuación estimada produce un número para cualquier combinación de predictores, pero la evidencia solo existe donde hubo observaciones. La región cubierta por los datos se llama **alcance del modelo**.

Extrapolación. Usar el modelo fuera del rango observado. Una relación puede ser aproximadamente lineal dentro del rango y curva fuera de él; el cálculo es siempre posible, pero nada garantiza que la relación estimada se mantenga.




Figura 4. Riesgo de la extrapolación. Dentro de la banda sombreada la recta describe bien las medias; fuera de ella se aparta cada vez más del comportamiento real.

Poca variabilidad en un predictor. Si los valores de X_j se concentran en un rango muy corto, hay poca información sobre cómo cambia la media al cambiar X_j : la pendiente queda dominada por la variabilidad condicional, su varianza es grande (Sección 6.2) y un solo valor extremo puede cambiarla por completo.

Predictores muy correlacionados. Si dos predictores están fuertemente correlacionados (por ejemplo, largo de pierna y largo de brazo, o edad de una vaca y número de partos), cada uno aporta muy poco una vez que el otro está en el modelo, sus coeficientes se vuelven inestables y sus errores estándar crecen. Es el problema de **multicolinealidad**; lo usual es no dejar ambos en el modelo.

5. Correlación y coeficientes estandarizados

5.1. Correlación

El coeficiente de correlación mide la fuerza y dirección de la asociación entre dos variables cuantitativas, con $-1 \leq r \leq 1$. El de **Pearson** mide asociación **lineal**; el de **Spearman**, calculado sobre rangos, mide asociación **monótona**.

Correlación cero no es independencia

Si dos variables son independientes, su correlación es cero. Lo contrario no se cumple: una relación curva que sube y luego baja puede dar $r \approx 0$. Un valor cercano a cero solo indica ausencia del tipo de asociación que mide ese coeficiente.

En regresión, la correlación se revisa en dos direcciones: entre cada predictor y la respuesta (qué variables prometen) y entre pares de predictores (posible multicolinealidad).

5.2. El problema de las escalas

La magnitud de $\hat{\beta}_j$ depende de la unidad de X_j . La misma relación medida en colones o en miles de colones da coeficientes que difieren en un factor de mil. Por eso **no se pueden comparar los coeficientes sin estandarizar** para decidir qué predictor tiene mayor impacto: un año, un kilogramo y un centímetro no son cantidades comparables.

5.3. Cómo estandarizar

Estandarizar una variable es restarle su media y dividirla entre su desviación estándar:

$$X^S = \frac{X - \bar{X}}{s_X}, \quad Y^S = \frac{Y - \bar{Y}}{s_Y}. \quad (10)$$

La variable queda centrada en cero y medida en desviaciones estándar. Al ajustar el modelo con todas las variables estandarizadas se obtienen los **coeficientes estandarizados** $\hat{\beta}_S$:

$$\hat{y}^S = \hat{\beta}_{S,1}x_1^S + \hat{\beta}_{S,2}x_2^S + \cdots + \hat{\beta}_{S,p-1}x_{p-1}^S. \quad (11)$$

El modelo **no lleva intercepto**: todas las variables están centradas, así que cuando todos los predictores valen cero (sus medias) la respuesta estandarizada también vale cero.

Coeficiente estandarizado

$\hat{\beta}_{S,j}$ es el número de desviaciones estándar que cambia la media de Y cuando X_j aumenta una desviación estándar, manteniendo constantes los demás predictores. Su signo es el mismo que el de $\hat{\beta}_j$.

Tres vías, un mismo resultado

1. **Desde las correlaciones:** $\hat{\beta}_S = r_{XX}^{-1} r_{XY}$, donde r_{XX} es la matriz de correlaciones entre los predictores y r_{XY} el vector de correlaciones de cada predictor con la respuesta.
2. **Estandarizando los datos:** transformar todas las variables y ajustar el modelo sin intercepto.
3. **Desde los coeficientes originales:**

$$\hat{\beta}_{S,j} = \hat{\beta}_j \times \frac{s_{X_j}}{s_Y}.$$

La tercera vía es la más útil cuando solo se tienen los coeficientes y las desviaciones estándar. Se lee como una traducción de unidades: $\hat{\beta}_j$ es el cambio por una unidad; multiplicado por s_{X_j} da el cambio por una desviación estándar del predictor; dividido entre s_Y ese cambio queda en desviaciones estándar de la respuesta.

La primera vía muestra además que los coeficientes estandarizados dependen solo de correlaciones: las unidades desaparecen del cálculo. Las variables categóricas codificadas como 0 y 1 no se estandarizan.

5.4. Cuál predictor tiene mayor impacto

Se comparan los **valores absolutos** de los coeficientes estandarizados; el signo solo indica la dirección.

Ejemplo: tallos de caña

Con $s_Y = 0.35$ kg:

Predictor	$\hat{\beta}_j$	s_{X_j}	$\hat{\beta}_{S,j} = \hat{\beta}_j s_{X_j} / s_Y$
Altura (m)	0.68	0.36	0.70
Cantidad	0.02	2.11	0.12
Grosor (cm)	0.49	0.38	0.53
Longitud (cm)	-0.00004	4.11	≈ 0.00

La altura tiene el mayor impacto, seguida del grosor. Sin estandarizar, la altura también tenía el mayor coeficiente, pero la cantidad de entrenudos parecía despreciable frente al grosor por una razón que es solo de unidades.

Para ordenar no hace falta dividir entre s_Y

Como s_Y es la misma para todos los predictores, el orden de $|\hat{\beta}_j s_{X_j}|$ es el mismo que el de $|\hat{\beta}_{S,j}|$. Esa cantidad es el cambio en la media de Y , en sus unidades originales, por un aumento de una desviación estándar en X_j .

5.5. Volver a las unidades originales

Decir que la media cambia 0.70 desviaciones estándar no comunica mucho hasta traducirlo. Si X_j aumenta s_{X_j} unidades, la media de Y cambia

$$\hat{\beta}_{S,j} \times s_Y = \hat{\beta}_j \times s_{X_j} \text{ unidades de } Y. \quad (12)$$

En la caña, al aumentar la altura 0.36 m manteniendo constantes las demás variables, el peso promedio aumenta $0.70 \times 0.35 = 0.245$ kg. Por la otra vía, $0.68 \times 0.36 = 0.245$ kg.

Lo que un coeficiente estandarizado no dice

Compara magnitudes dentro de un modelo concreto. No es una medida causal y cambia si se agregan o quitan variables, sobre todo si los predictores están correlacionados: lo que le queda por explicar a cada uno depende de cuáles otros estén presentes.

6. La variabilidad de las estimaciones

Si se tomaran muchas muestras de la misma población se obtendrían rectas distintas: los valores posibles de $\hat{\beta}$ forman su **distribución muestral**. En el modelo clásico la matriz X se considera fija, así que toda la variabilidad de $\hat{\beta} = (X'X)^{-1}X'Y$ viene de Y , y la variabilidad de Y la describe σ^2 .

6.1. Estimación de la varianza condicional: el CMRes

$$\hat{\sigma}^2 = \text{CMRes} = \frac{\text{SCRes}}{n - p} \quad (13)$$

Se divide entre $n - p$ y no entre n porque de las n observaciones se “gastaron” p en estimar los coeficientes; con n la estimación es sesgada. La raíz $\sqrt{\text{CMRes}}$ es la **desviación estándar residual**.

CMRes estima la varianza de Y dentro de una subpoblación, es decir, entre individuos con los mismos valores de todos los predictores del modelo. Por homocedasticidad es la misma para cualquier combinación de valores.

Por qué omitir una variable importante infla el CMRes

Si una variable importante queda fuera, cada subpoblación reúne individuos que difieren en esa variable, y esas diferencias se traducen en diferencias de Y dentro de la subpoblación. La variabilidad condicional aumenta y el CMRes crece.

Ejemplo: tallos de caña, $n = 60$

Con los cuatro predictores, $\text{SCRes} = 0.607$ y $\text{CMRes} = 0.607/(60 - 5) = 0.0110$. Sin la altura, $\text{SCRes} = 1.498$ y $\text{CMRes} = 1.498/(60 - 4) = 0.0268$, más del doble: sin fijar la altura, cada subpoblación mezcla tallos de alturas distintas, que es el predictor con mayor impacto.

Aumentar n no hace más pequeño el CMRes

σ^2 es una característica de la población condicionada en esas variables, no de la muestra. Con más datos el CMRes estima el **mismo** σ^2 , solo que con más estabilidad (varía menos de muestra en muestra). Lo que sí disminuye al aumentar n son las varianzas de $\hat{\beta}$ y de $\hat{y}_h$.

6.2. Varianza de los coeficientes

Bajo homocedasticidad e independencia ($V(Y) = \sigma^2 I$):

$$V(\hat{\beta}) = \sigma^2 (X'X)^{-1}, \quad \hat{V}(\hat{\beta}) = \text{CMRes} (X'X)^{-1}. \quad (14)$$

La variabilidad de los coeficientes depende de dos cosas y de nada más: de cuánta variabilidad condicional queda (σ^2) y de cómo están distribuidos los predictores en la muestra ($(X'X)^{-1}$). La matriz se lee por posiciones:

$$\hat{V}(\hat{\beta}) = \begin{bmatrix} \hat{V}(\hat{\beta}_0) & \widehat{\text{Cov}}(\hat{\beta}_0, \hat{\beta}_1) & \cdots \\ \widehat{\text{Cov}}(\hat{\beta}_1, \hat{\beta}_0) & \hat{V}(\hat{\beta}_1) & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}.$$

En la diagonal están las varianzas; fuera de ella, las covarianzas entre pares de coeficientes. Es simétrica.

Caso de regresión simple

Con un solo predictor la varianza de la pendiente tiene una forma que deja ver todo:

$$V(\hat{\beta}_1) = \frac{\sigma^2}{\sum_i (x_i - \bar{x})^2} = \frac{\sigma^2}{(n-1) s_X^2}. \quad (15)$$

La pendiente se estima con más precisión cuando hay **menos variabilidad condicional** (σ^2 pequeño), **más observaciones** (n grande) y **más dispersión en el predictor** (s_X^2 grande). Esta última es la razón formal por la que un rango corto de X produce pendientes poco confiables.

6.3. Errores estándar

$$EE(\hat{\beta}_j) = \sqrt{\hat{V}(\hat{\beta}_j)} = \sqrt{CMRes \cdot c_{jj}}, \quad (16)$$

donde c_{jj} es el elemento j de la diagonal de $(X'X)^{-1}$.

Error estándar

Es la **estimación de la desviación estándar de la distribución muestral** del estimador. La desviación estándar verdadera describe cuánto variaría $\hat{\beta}_j$ si el estudio se repitiera muchas veces; como el estudio se hace una vez, lo que se calcula es una estimación de esa cantidad.

- Un EE pequeño indica que es **más probable** que la estimación esté cerca del valor verdadero. No garantiza que lo esté: garantiza que la distribución del estimador está más concentrada alrededor del parámetro. Por eso conviene que la varianza de la pendiente sea pequeña.
- Un EE no se compara con el de otro coeficiente, porque cada uno está en las unidades de su variable. Sí tiene sentido compararlo con su propio coeficiente: el cociente $\hat{\beta}_j/EE$ no depende de la escala.

6.4. ¿Qué pasa si...?

Situación	CMRes	$V(\hat{\beta}_j)$ y EE	Intervalos
Aumenta n	Estima el mismo σ^2 , con más estabilidad	Disminuyen	Más angostos para β_j y para la media; el individual casi no se angosta
Se omite una variable importante	Aumenta	Suelen aumentar	Más anchos; además cambia el significado de los coeficientes restantes
Se agrega una variable sin relación con Y	Prácticamente igual (pierde un grado de libertad)	Pueden aumentar si esa variable se correlaciona con otras	Casi iguales o algo más anchos; R^2 sube un poco
X_j con rango muy corto	No cambia	$V(\hat{\beta}_j)$ aumenta	Intervalo de β_j muy ancho
Predictores muy correlacionados	Casi no cambia	Aumentan para esos predictores	Anchos; coeficientes inestables
X_j cambia de unidades ($\times c$)	Igual	$EE(\hat{\beta}_j)$ se divide entre c	Límites divididos entre c ; t , p y R^2 iguales

7. Intervalos de confianza

Todos los intervalos de este curso tienen la misma estructura:

$$\text{estimación} \pm t_{1-\alpha/2, n-p} \times \text{EE}. \quad (17)$$

Se usa la distribución t y no la normal porque el EE usa CMRes, una varianza **estimada**, y los grados de libertad son los mismos $n - p$ con que se construyó el CMRes.

7.1. Para un coeficiente

$$\hat{\beta}_j \pm t_{1-\alpha/2, n-p} \text{EE}(\hat{\beta}_j). \quad (18)$$

Cómo se lee

1. **Signo.** Si ambos límites tienen el mismo signo, hay una dirección definida del efecto y el intervalo se interpreta. Si contiene el cero, caben efectos positivos y negativos: no se ha demostrado relación entre ese predictor y la media de Y en ese modelo, y el intervalo no se interpreta como un aumento o disminución.
2. **Escala.** Se multiplican ambos límites por un aumento k que tenga sentido.

3. **Intercepto.** Normalmente no se interpreta.

Intervalo y prueba dicen lo mismo

El intervalo de $100(1-\alpha)\%$ para β_j contiene el cero si y solo si no se rechaza $H_0 : \beta_j = 0$ con la prueba bilateral de nivel α .

Ejemplo: altura en la caña

El intervalo de 95 % es (0.53, 0.83) con $n = 60$ y $p = 5$. De ahí se recuperan la estimación y su EE: $\hat{\beta}_1 = 0.68$ (el centro) y $EE = 0.15/t_{0.975,55} = 0.15/2.004 = 0.075$. Con un aumento de 0.35 m: con 95 % de confianza, al aumentar la altura 0.35 m manteniendo constantes grosor, cantidad y longitud de entrenudos, el peso promedio de los tallos aumenta entre 0.19 y 0.29 kg.

7.2. Para la media condicional

Se arma x_h y se calcula $\hat{y}_h = x_h' \hat{\beta}$. Como $\hat{y}_h$ es una combinación lineal de los coeficientes, su varianza se obtiene con la matriz completa:

$$\hat{V}(\hat{y}_h) = x_h' \hat{V}(\hat{\beta}) x_h, \quad EE(\hat{y}_h) = \sqrt{x_h' \hat{V}(\hat{\beta}) x_h}, \quad (19)$$

$$\hat{y}_h \pm t_{1-\alpha/2, n-p} EE(\hat{y}_h). \quad (20)$$

Aquí sí importan las covarianzas: al multiplicar por x_h a ambos lados entran todos los elementos de la matriz, no solo la diagonal.

Caso de regresión simple

Con $x_h = (1, x_h)'$ y la matriz de 2×2 , el producto se desarrolla a mano:

$$\hat{V}(\hat{y}_h) = \hat{V}(\hat{\beta}_0) + x_h^2 \hat{V}(\hat{\beta}_1) + 2x_h \widehat{Cov}(\hat{\beta}_0, \hat{\beta}_1). \quad (21)$$

Equivalentemente,

$$\hat{V}(\hat{y}_h) = \text{CMRes} \left[\frac{1}{n} + \frac{(x_h - \bar{x})^2}{\sum_i (x_i - \bar{x})^2} \right]. \quad (22)$$

Dónde se estima mejor la media

El término $(x_h - \bar{x})^2$ muestra que la varianza es mínima en $x_h = \bar{x}$ y crece al alejarse de la media del predictor. La media se estima con más precisión en el centro de los datos que en los bordes, y con muy poca precisión fuera del rango observado.

7.3. Para valores individuales

Si la pregunta no es por la media de un grupo sino por dónde puede caer el valor de un individuo, hay que sumar la variabilidad natural de los individuos alrededor de la media:

$$\hat{V}(Y | x_h) = \hat{V}(\hat{y}_h) + \text{CMRes}, \quad \hat{y}_h \pm t_{1-\alpha/2, n-p} \sqrt{\hat{V}(\hat{y}_h) + \text{CMRes}}. \quad (23)$$

Aparecen dos términos porque CMRes mide la dispersión alrededor de la media **verdadera**, que no se conoce; en el centro del intervalo está la media **estimada**, que aporta su propia variabilidad.

Se suman varianzas, no errores estándar

Primero se suman $\hat{V}(\hat{y}_h)$ y CMRes, y solo al final se saca la raíz. $\sqrt{a+b} \neq \sqrt{a} + \sqrt{b}$.

7.4. Comparación entre ambos intervalos

	Para la media	Para individuos
Pregunta	¿Cuál es el promedio de Y para esas características?	¿Entre qué valores cae Y para los individuos con esas características?
Varianza	$x'_h \hat{V}(\hat{\beta}) x_h$	$x'_h \hat{V}(\hat{\beta}) x_h + \text{CMRes}$
Centro	$\hat{y}_h$	$\hat{y}_h$ (el mismo)
Si $n \rightarrow \infty$	El ancho tiende a cero	El ancho tiende a $\pm t \sigma$: la variabilidad individual no desaparece
Redacción	“la media de Y ... está entre”	“el 95 % de los individuos ... tiene Y entre”

Leer bien la pregunta

“¿Cuál es el valor estimado?” o “¿cuál es el promedio?” piden la media. “¿Cuánto se espera que mida **una** persona (un tallo, una vaca)?” pide el intervalo individual, porque el valor de un individuo no es un promedio.

Ejemplo: peso del tallo según la altura

Con 40 tallos, $\bar{x} = 1.956$ m y altura máxima observada de 2.49 m:

- En $x_h = 2$: $\hat{y}_h = 0.917$ kg, intervalo para la media (0.845, 0.989), ancho 0.144.
- En $x_h = 2.5$: $\hat{y}_h = 1.235$ kg, intervalo para la media (1.093, 1.376), ancho 0.282.
- En $x_h = 2$, intervalo para individuos: (0.460, 1.374).

El intervalo en 2.5 m es casi el doble de ancho porque 2.5 está mucho más lejos de $\bar{x}$ que 2, y además queda en el borde (ligeramente fuera) del rango observado.




Figura 5. Límites para la media y para individuos. Ambos están centrados en la misma recta. Los límites individuales son siempre más anchos porque suman el CMRes. Los dos se estrechan en $\bar{x}$ y se abren hacia los extremos; a partir del máximo observado se está extrapolando.

7.5. Flujo para construir un intervalo

Paso 1. Identificar qué se pide: un coeficiente, la media de una subpoblación o el valor de individuos.

Paso 2. Obtener el centro.

↪ Coeficiente: $\hat{\beta}_j$.

↪ Media o individuos: armar x_h en el orden de $\hat{\beta}$ y calcular $\hat{y}_h = x_h' \hat{\beta}$.

Paso 3. Obtener la varianza.

↪ Coeficiente: elemento j de la diagonal de $\hat{V}(\hat{\beta}) = \text{CMRes}(X'X)^{-1}$.

↪ Media: $x_h' \hat{V}(\hat{\beta}) x_h$.

↪ Individuos: $x_h' \hat{V}(\hat{\beta}) x_h + \text{CMRes}$.

Paso 4. Raíz cuadrada para el EE y valor $t_{1-\alpha/2, n-p}$, con p del modelo usado.

Paso 5. Límites: centro $\pm t \times \text{EE}$.

Paso 6. Interpretar.

↪ Coeficiente: revisar signos; si no contiene el cero, multiplicar por k y redactar.

↪ Media: redactar con “la media” o “el promedio”.

↪ Individuos: redactar con “el 95 % de los individuos”.

8. Descomposición de la variabilidad

8.1. La suma de cuadrados total

$$\text{SCTot} = \sum_{i=1}^n (y_i - \bar{y})^2 = (n-1) s_Y^2. \quad (24)$$

Las distancias se miden al promedio general, no a la recta, así que la SCTot **no depende del modelo**: es la misma para cualquier conjunto de predictores y se calcula antes de ajustar nada. Es el techo: la variabilidad total que cualquier modelo intenta explicar y que ningún modelo puede superar.

8.2. La partición

La desviación de cada observación respecto a la media general se separa en dos tramos:

$$\underbrace{y_i - \bar{y}}_{\text{total}} = \underbrace{(\hat{y}_i - \bar{y})}_{\text{explicada}} + \underbrace{(y_i - \hat{y}_i)}_{\text{residuo}}. \quad (25)$$




Figura 6. Partición de la desviación de una observación. Del promedio general al valor ajustado (cruz azul) está la parte explicada; del valor ajustado a la observación, el residuo.

Al elevar al cuadrado y sumar sobre todas las observaciones, el doble producto $2 \sum (\hat{y}_i - \bar{y})(y_i - \hat{y}_i)$ vale cero. Se anula en la **suma**, no en cada observación, por lo que la partición vale para el conjunto de datos:

$$\boxed{\text{SCTot} = \text{SCReg} + \text{SCRes}} \quad \text{SCReg} = \sum (\hat{y}_i - \bar{y})^2, \quad \text{SCRes} = \sum (y_i - \hat{y}_i)^2. \quad (26)$$

SC	Qué mide
SCTot	Variabilidad de Y alrededor de su media. No depende del modelo.
SCReg	Cuánto se alejan las medias condicionales estimadas de la media general: la variabilidad explicada por los predictores. Si fuera cero, la superficie sería horizontal.
SCRes	Lo que queda de cada observación respecto a su media estimada: la variabilidad que los predictores no explican. Es la misma cantidad que minimiza MCO.

8.3. Grados de libertad y tabla de análisis de varianza

Fuente	GL	SC	CM
Regresión	$p - 1$	SCReg	$\text{CMReg} = \text{SCReg}/(p - 1)$
Residuo	$n - p$	SCRes	$\text{CMRes} = \text{SCRes}/(n - p)$
Total	$n - 1$	SCTot	

Una suma de cuadrados crece simplemente por acumular términos; al dividirla entre sus grados de libertad queda expresada por unidad de información, que es la forma en que dos fuentes se pueden comparar. Una SC y un CM no están en la misma escala.

8.4. Coeficiente de determinación

$$R^2 = \frac{\text{SCReg}}{\text{SCTot}} = 1 - \frac{\text{SCRes}}{\text{SCTot}} \quad 0 \leq R^2 \leq 1. \quad (27)$$

R^2 es la proporción de la variabilidad total de Y explicada **conjuntamente** por los predictores del modelo. La segunda forma es la más práctica, porque SCTot sale de s_Y y SCRes de los residuos.

Ejemplo: tallos de caña, $n = 60$, $s_Y = 0.35188$ kg

$\text{SCTot} = 59(0.35188)^2 = 7.305$. Con los cuatro predictores, $R^2 = 1 - 0.607/7.305 = 0.917$: las cuatro variables explican el 91.7 % de la variabilidad del peso. Con solo la altura, $\text{SCRes} = 2.975$ y $R^2 = 1 - 2.975/7.305 = 0.593$.

Cuánto es suficiente

No hay un umbral universal: depende del área. Con instrumentos precisos un 50 % puede ser modesto; con variables subjetivas (cuestionarios) puede ser notable. Lo razonable es compararlo con estudios similares. Un R^2 cercano a 1 en datos reales debe hacer sospechar, por ejemplo, que la respuesta se construyó con los mismos predictores que se están usando.

R^2 no sirve para decidir si agregar una variable

La SCTot es fija y la SCRes **nunca aumenta** al agregar un predictor: en el peor caso MCO le asigna un coeficiente de cero y la SCRes queda igual. Por eso R^2 casi siempre sube con más variables, incluso sin relación con Y . La pregunta útil no es si la SCRes bajó, sino **cuánto** bajó, y eso lo formaliza la prueba F.

9. Aporte marginal y comparación de modelos anidados

9.1. Suma de cuadrados de regresión marginal

El aporte de X_2 cuando entra a un modelo que ya contiene X_1 es

$$\text{SCReg}(X_2 | X_1) = \text{SCReg}(X_1, X_2) - \text{SCReg}(X_1) = \text{SCRes}(X_1) - \text{SCRes}(X_1, X_2) \quad (28)$$

La forma con SCRes es la más cómoda, y la resta siempre es **modelo pequeño menos modelo grande**, porque el pequeño tiene la mayor SCRes; así la diferencia nunca es negativa.

Es como dos personas que exponen un mismo tema: la segunda solo puede decir lo que la primera no dijo. Lo que se mide no es cuánto sabe, sino cuánto aporta después. Si los temas no se traslapan el orden no importa; con los predictores, el traslape es la correlación entre ellos.

- El aporte de una variable **depende de cuáles ya están** en el modelo.

- Con frecuencia una variable aporta menos al entrar de segunda, pero no es una regla: también puede aportar más.
- Los aportes marginales de varias variables en general no suman su aporte conjunto.




Figura 7. El orden de entrada cambia el aporte (tallos de caña). La SCTot es la misma en las cuatro barras. Sola, la altura explica 4.330; después de grosor, cantidad y longitud solo agrega 0.891, porque parte de lo que explica ya lo explicaban las otras. En ambos órdenes el modelo completo termina con la misma SCRes de 0.607.

9.2. La tabla de análisis de varianza secuencial

Cuando la tabla de análisis de varianza de un modelo reporta una fila por variable, las sumas de cuadrados son **secuenciales**: la de cada fila es el aporte marginal de esa variable dado que ya entraron **las que están arriba de ella**.

- Las filas de las variables suman la SCReg del modelo.
- El orden en que se escriben los predictores cambia las SC de cada fila, pero no la SCRes.
- Para leer el aporte de una variable después de todas las demás, esa variable tiene que estar en la última fila.

9.3. Coeficiente de determinación parcial

$$R_{Y2|1}^2 = \frac{\text{SCReg}(X_2 | X_1)}{\text{SCRes}(X_1)} = \frac{\text{SCRes}(X_1) - \text{SCRes}(X_1, X_2)}{\text{SCRes}(X_1)} \quad (29)$$

Mientras R^2 compara lo explicado con el total, R^2 parcial compara el aporte de X_2 con **lo que X_1 había dejado sin explicar**. Es la proporción de la variabilidad residual del modelo pequeño que se logra explicar al agregar X_2 .

Ejemplo: tallos de caña

La altura, al entrar después de las otras tres, explica $0.891/1.498 = 0.595$: el 59.5 % de la variabilidad que grosor, cantidad y longitud habían dejado sin explicar. Las otras tres, al entrar después de la altura, explican $2.368/2.975 = 0.796$ de lo que la altura dejó sin explicar.

9.4. Modelos anidados

Modelo anidado

Un modelo w está anidado en un modelo W si **todas** las variables de w están también en W . No basta con compartir algunas.

Un modelo con edad, pierna e imc contiene a uno con solo edad y a uno con pierna e imc. Pero el de solo edad y el de pierna e imc no están anidados entre sí, ni lo están un modelo con edad y pierna y otro con edad y brazo.

La pregunta es si las variables que están en W y no en w explican lo suficiente de la variabilidad restante como para justificar el modelo grande. Si no, se prefiere w por **parsimonia**: entre dos modelos que explican lo mismo, el más simple.

9.5. La prueba F

Si W agrega q coeficientes a w :

$$H_0 : w \text{ y } W \text{ explican lo mismo} \Leftrightarrow H_0 : \beta_{(1)} = \beta_{(2)} = \cdots = \beta_{(q)} = 0, \quad (30)$$

donde los $\beta_{(i)}$ son los coeficientes de las variables adicionales. La alternativa es que **al menos uno** es distinto de cero.

$$F = \frac{[\text{SCRes}(w) - \text{SCRes}(W)]/q}{\text{CMRes}(W)} \sim F_{q, n-p} \text{ bajo } H_0 \quad (31)$$

con p el número de coeficientes del modelo **grande**. El numerador es el aporte marginal por grado de libertad; el denominador, la variabilidad que el modelo grande deja sin explicar. F dice cuántas veces el aporte, por grado de libertad, supera al CMRes.

Cómo contar q

q es el número de igualdades en H_0 , que es lo mismo que la diferencia en el número de coeficientes entre W y w .

La misma prueba escrita con R^2

Como $SCRes = (1 - R^2) SCTot$ y la $SCTot$ es la misma en ambos modelos,

$$F = \frac{(R_W^2 - R_w^2)/q}{(1 - R_W^2)/(n - p)}.$$

La decisión

Se calcula la probabilidad de obtener un valor mayor que el F observado en la distribución $F_{q, n-p}$. Esa probabilidad es el riesgo de cometer error tipo I si se rechaza H_0 . Si no supera el nivel α fijado de antemano, se rechaza.

El valor de F no se lee de forma absoluta: un mismo F puede llevar a rechazar con muchos grados de libertad en el denominador y no rechazar con pocos.




Figura 8. Distribución F con 3 y 55 grados de libertad. Cualquier F observado a la derecha de 2.77 tiene probabilidad asociada menor que 0.05 y lleva a rechazar H_0 . En el ejemplo de la caña el valor observado queda muy lejos, fuera del gráfico.

Ejemplo: ¿vale la pena agregar grosor, cantidad y longitud a la altura?

w : solo altura, $SCRes = 2.975$. W : las cuatro variables, $SCRes = 0.607$, $n = 60$, $p = 5$, $q = 3$.

$$H_0 : \beta_{\text{grosor}} = \beta_{\text{cantidad}} = \beta_{\text{longitud}} = 0, \quad F = \frac{(2.975 - 0.607)/3}{0.607/55} = \frac{0.789}{0.01104} = 71.5.$$

Con $p < 0.0001$ se rechaza H_0 : al menos una de las tres variables aporta explicación del peso promedio después de la altura, y se prefiere el modelo con las cuatro. Eso no descarta que un modelo intermedio sea igual de bueno.

9.6. Casos particulares

Cuando se quita una sola variable ($q = 1$)

La hipótesis se reduce a $H_0 : \beta_j = 0$, que también se prueba con

$$t = \frac{\hat{\beta}_j}{\text{EE}(\hat{\beta}_j)} \sim t_{n-p}, \quad \boxed{F = t^2}. \quad (32)$$

La t es bilateral (solo interesa si es distinto de cero) y la F se lee por una cola; ambas dan la misma probabilidad. La equivalencia solo existe con un grado de libertad en el numerador.

Ejemplo: la altura después de las otras tres

$F = (1.498 - 0.607)/0.01104 = 80.7$, de modo que $t = \sqrt{80.7} = 8.98$. Con $\hat{\beta} = 0.68$ esto da $\text{EE} = 0.68/8.98 = 0.076$, que coincide con el obtenido del intervalo de confianza.

Cada línea de coeficientes en el resumen de un modelo es exactamente esta prueba: comparar el modelo completo contra el modelo al que se le quita **solo** esa variable.

Una a la vez

Si varias líneas no son significativas, eso no autoriza a quitar todas esas variables juntas: cada prueba supone que las demás siguen en el modelo. Para quitar un grupo se hace la prueba F conjunta.

La prueba ómnibus

Compara el modelo completo contra el **modelo nulo**, que solo tiene intercepto:

$$\mu_{Y|x} = \beta_0, \quad \hat{\beta}_0 = \bar{y}, \quad \text{SCRes}(\text{nulo}) = \text{SCTot}. \quad (33)$$

Por eso el aporte de todos los predictores juntos es la SCReg del modelo completo:

$$H_0 : \beta_1 = \dots = \beta_{p-1} = 0, \quad F = \frac{\text{SCReg}/(p-1)}{\text{CMRes}} = \frac{\text{CMReg}}{\text{CMRes}} \sim F_{p-1, n-p}. \quad (34)$$

Rechazarla es lo mínimo para seguir con el análisis: indica que al menos un predictor explica algo. No dice cuáles ni cuántos. En la caña, $F = [(7.305 - 0.607)/4]/0.01104 = 151.7$, con $p < 0.0001$.

9.7. Errores al comparar modelos

Error	Consecuencia
Tipo I (rechazar sin que las variables aporten)	Se queda con un modelo más grande de lo necesario: se gastan grados de libertad y se incluyen coeficientes que solo describen ruido.
Tipo II (no rechazar cuando sí aportan)	Se eliminan variables útiles: la variabilidad condicional queda inflada, el CMRes sobreestima la del modelo correcto, los intervalos son más anchos y los coeficientes restantes cambian de significado.

9.8. Flujo para comparar modelos

Paso 1. Verificar que los modelos están anidados. Si no, esta prueba no aplica.

Paso 2. Escribir ambos modelos y H_0 con símbolos y con palabras. Contar q .

Paso 3. Obtener $\text{SCRes}(w)$, $\text{SCRes}(W)$ y $\text{CMRes}(W) = \text{SCRes}(W)/(n - p)$.

Paso 4. Aporte marginal: $\text{SCRes}(w) - \text{SCRes}(W)$. Si se pide, R^2 parcial: $\text{aporte}/\text{SCRes}(w)$.

Paso 5. $F = [\text{aporte}/q]/\text{CMRes}(W)$ y probabilidad en $F_{q, n-p}$.

Si se rechaza H_0 :

$\hookrightarrow$ Al menos una de las variables adicionales aporta; se prefiere W .

$\hookrightarrow$ No se sabe cuál: si se necesita, pruebas t en W (una variable a la vez).

Si no se rechaza H_0 :

$\hookrightarrow$ No hay evidencia de que aporten después de las de w ; se prefiere w por parsimonia.

$\hookrightarrow$ No se afirma que sus coeficientes sean cero, solo que no se demostró lo contrario.

Casos especiales: $q = 1 \Rightarrow F = t^2$; w nulo $\Rightarrow$ omnibus con $\text{SCRes}(w) = \text{SCTot}$.

10. Cómo reconstruir resultados con información parcial

Muchas veces no se tienen los datos, sino piezas: una desviación estándar, algunas SCRes, un intervalo, una tabla de coeficientes. Casi todo se despeja con unas pocas identidades.

Si se conoce	Se obtiene	Con
s_Y y n	SCTot	$(n-1)s_Y^2$
SCRes, n , p	CMRes	SCRes/ $(n-p)$
Desviación estándar residual	CMRes	su cuadrado
GL del residuo y p	n	GL + p
SCRes y SCTot	R^2 y SCReg	$1 - \text{SCRes}/\text{SCTot}$; $\text{SCTot} - \text{SCRes}$
R^2 y SCTot	SCRes	$(1 - R^2) \text{SCTot}$
SCRes de dos modelos anidados	aporte marginal, F , R^2 parcial	Sección 9
R^2 de dos modelos anidados	F	$\frac{(R_W^2 - R_w^2)/q}{(1 - R_W^2)/(n-p)}$
$\hat{\beta}_j$ y EE	t	$\hat{\beta}_j/\text{EE}$
$\hat{\beta}_j$ y t	EE	$\hat{\beta}_j/t$
t de un coeficiente	F de quitar esa variable	t^2
Intervalo (L, U) para β_j	$\hat{\beta}_j$ y EE	$(L+U)/2$; $(U-L)/(2t_{1-\alpha/2, n-p})$
CMRes y $(X'X)^{-1}$	EE($\hat{\beta}_j$)	$\sqrt{\text{CMRes} \cdot c_{jj}}$
$\hat{\beta}_j$, s_{X_j} , s_Y	$\hat{\beta}_{S,j}$	$\hat{\beta}_j s_{X_j}/s_Y$
$\hat{\beta}_{S,j}$ y s_Y	cambio en unidades de Y	$\hat{\beta}_{S,j} s_Y$ por cada s_{X_j}
Medias de los predictores	$\hat{y}$ en esas medias	$\bar{y}$
$\hat{y}$ en x y $\hat{\beta}_1$ (simple)	$\hat{y}$ en x'	$\hat{y}(x) + \hat{\beta}_1(x' - x)$
$\hat{V}(\hat{\beta})$ de 2×2 y x_h	$\hat{V}(\hat{y}_h)$	$\hat{V}(\hat{\beta}_0) + x_h^2 \hat{V}(\hat{\beta}_1) + 2x_h \widehat{Cov}$
Intervalo para la media	EE($\hat{y}_h$)	semiancho/ $t_{1-\alpha/2, n-p}$
EE($\hat{y}_h$) y CMRes	intervalo individual	$\hat{y}_h \pm t\sqrt{\text{EE}^2 + \text{CMRes}}$

Ejemplo integrador: tallos de caña

Se sabe que hay $n = 60$ tallos, que $s_Y = 0.35188$ kg y que la SCRes es 0.607 con los cuatro predictores, 2.975 con solo la altura y 1.498 con las otras tres. Con eso:

1. SCTot = $59(0.35188)^2 = 7.305$: es lo máximo que cualquier modelo puede explicar.
2. R^2 del modelo completo: $1 - 0.607/7.305 = 0.917$. De solo la altura: 0.593.
3. CMRes del completo: $0.607/55 = 0.01104$; sin altura: $1.498/56 = 0.0268$.

4. Aporte de la altura después de las otras: $1.498 - 0.607 = 0.891$. Sola: $7.305 - 2.975 = 4.330$.
5. R^2 parcial de la altura: $0.891/1.498 = 0.595$.
6. Prueba para quitar la altura: $F = 0.891/0.01104 = 80.7$, $t = 8.98$, $p < 0.0001$.
7. Prueba para quitar las otras tres: $F = (2.368/3)/0.01104 = 71.5$, $p < 0.0001$.
8. Ómnibus: $F = (6.698/4)/0.01104 = 151.7$, $p < 0.0001$.

11. Cómo redactar las interpretaciones

Una interpretación completa tiene elementos que no pueden faltar: la palabra **promedio** o **media** cuando corresponde, la cláusula **manteniendo constantes** las demás variables, las **unidades**, la **subpoblación** a la que se refiere y el **nivel de confianza** en los intervalos.

Qué se interpreta	Plantilla
Coefficiente	Al comparar subpoblaciones cuyo $[X_j]$ difiere en $[k \text{ unidades}]$, manteniendo constantes [las demás], se espera que el/la $[Y]$ promedio [aumente/disminuya] $[k \hat{\beta}_j \text{ unidades}]$ en la subpoblación con mayor $[X_j]$.
Intervalo de β_j sin el cero	Con 95 % de confianza, al aumentar $[X_j]$ en $[k \text{ unidades}]$, manteniendo constantes [las demás], el/la $[Y]$ promedio [aumenta/disminuye] entre $[kL]$ y $[kU \text{ unidades}]$.
Intervalo de β_j con el cero	No se ha encontrado evidencia de que $[X_j]$ se asocie con un aumento o una disminución de $[Y]$ promedio, manteniendo constantes [las demás].
Coefficiente estandarizado	Al aumentar $[X_j]$ una desviación estándar ($[s_{X_j} \text{ unidades}]$), manteniendo constantes [las demás], el/la $[Y]$ promedio cambia $[\hat{\beta}_{S,j}]$ desviaciones estándar, es decir, $[\hat{\beta}_{S,j} s_Y \text{ unidades}]$.
Mayor impacto	$[X_j]$ tiene el mayor impacto porque su coeficiente estandarizado es el mayor en valor absoluto; los coeficientes sin estandarizar no se comparan porque dependen de las unidades.
Valor ajustado $\hat{y}_h$	Se estima que [los individuos] con $[X_1 = \dots, X_2 = \dots]$ tienen un/una $[Y]$ promedio de $[\hat{y}_h \text{ unidades}]$.
Media no condicional	$\bar{y}$ estima la media de $[Y]$ en toda la población, sin fijar ningún valor de los predictores.
Intervalo para la media	Con 95 % de confianza, el/la $[Y]$ promedio de [los individuos] con [características] está entre $[L]$ y $[U \text{ unidades}]$.

Qué se interpreta	Plantilla
Intervalo individual	Se espera que el 95 % de [los individuos] con [características] tenga un/una [Y] entre [L] y [U unidades].
CMRes	[CMRes] es la varianza estimada de [Y] entre [individuos] con los mismos valores de [predictores]; por homocedasticidad es la misma para cualquier combinación de valores.
CMRes mayor en un modelo	Al dejar fuera [variable importante], cada subpoblación mezcla individuos con distintos valores de ella, lo que aumenta la variabilidad condicional de [Y].
R^2	Las variables [lista] explican en conjunto el $[100R^2]$ % de la variabilidad de [Y].
Aporte marginal	Al agregar $[X_2]$ a un modelo que ya tiene $[X_1]$, la variabilidad explicada aumenta [SC], que es exactamente lo que baja la SCRes al incluirla.
R^2 parcial	$[X_2]$ explica el [%] de la variabilidad que $[X_1]$ había dejado sin explicar.
F: se rechaza	Se rechaza H_0 : al menos uno de los coeficientes de [variables adicionales] es distinto de cero; se prefiere el modelo con [variables de W], lo que no descarta un modelo intermedio.
F: no se rechaza	No se rechaza H_0 : no hay evidencia de que [variables adicionales] aporten después de [variables de w]; por parsimonia se prefiere el modelo más simple.

12. Preguntas conceptuales frecuentes

Pregunta	Respuesta corta
¿En qué consiste el método de mínimos cuadrados?	En elegir los coeficientes que minimizan la suma de los residuos al cuadrado, es decir, que dejan los valores ajustados lo más cerca posible de los observados.
¿Por qué máxima verosimilitud da los mismos coeficientes?	Bajo normalidad, $\log L = -\frac{n}{2} \log(\text{SCRes})$: maximizar L es minimizar SCRes.
¿Es correcto decir que si X aumenta una unidad, Y aumenta $\hat{\beta}_1$?	No. Aumenta la media de Y ; los valores individuales pueden ubicarse en cualquier parte de su distribución condicional.

Pregunta	Respuesta corta
¿Qué representa el error estándar de $\hat{\beta}_j$?	La estimación de la desviación estándar de la distribución muestral de $\hat{\beta}_j$: cuánto variaría la estimación entre muestras.
¿Por qué conviene que la varianza de la pendiente sea pequeña?	Porque así es más probable que la estimación esté cerca de la pendiente verdadera y los intervalos son más angostos.
¿La varianza condicional de Y es la varianza del error?	Sí: $\varepsilon = Y - \mu_{Y x}$ y restar una constante no cambia la varianza.
¿Dónde se usa la normalidad?	En las distribuciones t y F de intervalos y pruebas, y en la equivalencia MV-MCO. Para obtener $\hat{\beta}$ por MCO no se necesita.
¿Qué es la homocedasticidad?	Que $V(Y x) = \sigma^2$ para todo x : las distribuciones condicionales tienen el mismo ancho.
¿Qué significa que una media sea condicional?	Que es la media de una subpoblación definida por valores fijos de los predictores.
¿Por qué la SCTot es igual en todos los modelos?	Porque solo usa los valores de Y y su media; no depende de los predictores.
Si aumenta n , ¿qué pasa con el CMRes?	Estima el mismo σ^2 con más estabilidad; no tiende a bajar. Sí bajan las varianzas de los estimadores.
Dos personas estudian lo mismo con 20 y 40 datos, ¿cuál tiene el coeficiente más cercano al verdadero?	No se puede asegurar para una muestra concreta; con 40 la distribución del estimador tiene menor varianza, así que es más probable que esté cerca.
Si se elimina una variable importante, ¿en qué sentido las estimaciones son peores?	Aumenta la variabilidad condicional, crece el CMRes y con él los EE: estimaciones menos precisas e intervalos más anchos. Además cambia el significado de los coeficientes.
¿Por qué el intervalo individual es más ancho?	Porque además de la variabilidad de la media estimada suma la variabilidad de los individuos alrededor de la media (CMRes).
¿Por qué el intervalo para la media es más ancho en un valor de x que en otro?	Porque $V(\hat{y}_h)$ crece con la distancia de x_h a $\bar{x}$; más aún fuera del rango.
¿Por qué no se comparan coeficientes sin estandarizar?	Porque su magnitud depende de las unidades de cada predictor.
¿Conviene tener dos predictores muy correlacionados?	No: el segundo aporta muy poco después del primero y ambos coeficientes se vuelven inestables (multicolinealidad).

Pregunta	Respuesta corta
¿Por qué no usar R^2 para decidir si agregar una variable?	Porque nunca baja al agregar variables; se usa la prueba F.
¿Qué dimensión tiene $\hat{V}(\hat{\beta})$ con k predictores?	$(k+1) \times (k+1)$.

13. Puente con diseño de experimentos

La regresión y el análisis de varianza son el mismo modelo lineal visto desde dos lados, por lo que casi todo lo de diseño de experimentos tiene su contraparte:

Diseño de experimentos	Regresión	Qué comparten
SCTrat	SCReg	Variabilidad explicada por el modelo
CMRes	CMRes	Estimación de σ^2
μ_{ij} de un tratamiento	$\mu_{Y x}$ en un punto	Media condicional
Absorber SCInt al residuo (modelo SI dentro de CI)	SCRes(w)—SCRes(W)	Comparación de modelos anidados
$F_{\text{int}} = \text{CMInt}/\text{CMRes}^{CI}$	$F = [\text{aporte}/q]/\text{CMRes}(W)$	Aporte por GL entre CMRes del modelo grande
Contraste $v'\mu$	$x'_h\hat{\beta}$	Combinación lineal con varianza $v'\hat{V}v$
t de un contraste con 1 GL	t de un coeficiente	$F = t^2$
Bloque que reduce el residuo	Variable importante incluida	Menor variabilidad condicional

La prueba de interacción es literalmente una prueba F de modelos anidados: el modelo sin interacción está contenido en el modelo con interacción, y $\text{SCRes}^{SI} - \text{SCRes}^{CI} = \text{SCInt}$ es su aporte marginal.

14. Resumen de fórmulas clave

Modelo

$$\mu_{Y|x} = \beta_0 + \beta_1 x_1 + \cdots + \beta_{p-1} x_{p-1} \quad Y = \mu_{Y|x} + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2) \quad (35)$$

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \cdots + \hat{\beta}_{p-1} x_{p-1} \quad r = y - \hat{y} \quad (36)$$

Estimación

$$\hat{\beta} = (X'X)^{-1} X'Y \quad \hat{y}_h = x_h' \hat{\beta} \quad (37)$$

$$\text{CMRes} = \frac{\text{SCRes}}{n - p} \quad \hat{\sigma}_{MV}^2 = \frac{\text{SCRes}}{n} \text{ (sesgada)} \quad (38)$$

Coefficientes estandarizados

$$X^S = \frac{X - \bar{X}}{s_X} \quad \hat{\beta}_S = r_{XX}^{-1} r_{XY} \quad (39)$$

$$\hat{\beta}_{S,j} = \hat{\beta}_j \frac{s_{X_j}}{s_Y} \quad \text{cambio en } Y \text{ por } s_{X_j} = \hat{\beta}_{S,j} s_Y = \hat{\beta}_j s_{X_j} \quad (40)$$

Varianzas

$$\hat{V}(\hat{\beta}) = \text{CMRes} (X'X)^{-1} \quad \text{EE}(\hat{\beta}_j) = \sqrt{\text{CMRes} \cdot c_{jj}} \quad (41)$$

$$V(\hat{\beta}_1) = \frac{\sigma^2}{\sum (x_i - \bar{x})^2} \text{ (simple)} \quad \hat{V}(\hat{y}_h) = x_h' \hat{V}(\hat{\beta}) x_h \quad (42)$$

$$\hat{V}(\hat{y}_h) = \text{CMRes} \left[\frac{1}{n} + \frac{(x_h - \bar{x})^2}{\sum (x_i - \bar{x})^2} \right] \text{ (simple)} \quad \hat{V}(Y | x_h) = \hat{V}(\hat{y}_h) + \text{CMRes} \quad (43)$$

Intervalos de $100(1 - \alpha) \%$

$$\beta_j : \quad \hat{\beta}_j \pm t_{1-\alpha/2, n-p} \text{EE}(\hat{\beta}_j) \quad (44)$$

$$\mu_{Y|x_h} : \quad \hat{y}_h \pm t_{1-\alpha/2, n-p} \sqrt{x_h' \hat{V}(\hat{\beta}) x_h} \quad (45)$$

$$Y | x_h : \quad \hat{y}_h \pm t_{1-\alpha/2, n-p} \sqrt{x_h' \hat{V}(\hat{\beta}) x_h + \text{CMRes}} \quad (46)$$

Descomposición

$$\text{SCTot} = \sum (y_i - \bar{y})^2 = (n-1)s_Y^2 \quad \text{SCTot} = \text{SCReg} + \text{SCRes} \quad (47)$$

$$R^2 = \frac{\text{SCReg}}{\text{SCTot}} = 1 - \frac{\text{SCRes}}{\text{SCTot}} \quad R_{Y_2|1}^2 = \frac{\text{SCRes}(X_1) - \text{SCRes}(X_1, X_2)}{\text{SCRes}(X_1)} \quad (48)$$

$$\text{SCReg}(X_2 | X_1) = \text{SCRes}(X_1) - \text{SCRes}(X_1, X_2) \quad \text{GL: } p-1, \quad n-p, \quad n-1 \quad (49)$$

Pruebas

$$F = \frac{[\text{SCRes}(w) - \text{SCRes}(W)]/q}{\text{CMRes}(W)} \sim F_{q, n-p} \quad F = \frac{(R_W^2 - R_w^2)/q}{(1 - R_W^2)/(n-p)} \quad (50)$$

$$t = \frac{\hat{\beta}_j}{\text{EE}(\hat{\beta}_j)} \sim t_{n-p} \quad F = t^2 \quad (q=1) \quad (51)$$

$$F_{\text{ómnibus}} = \frac{\text{CMReg}}{\text{CMRes}} \sim F_{p-1, n-p} \quad \text{SCRes}(\text{nulo}) = \text{SCTot}, \quad \hat{\beta}_0 = \bar{y} \quad (52)$$

15. Videos de clase

1. **Clase 1:**
<https://youtu.be/Qsd0vrhCW-U>
2. **Clase 2:**
<https://youtu.be/s8P8m0LPx4s>
3. **Clase 3 :**
<https://youtu.be/NYm-HxPDb8c>
4. **Clase 4 :**
<https://youtu.be/tbR7oqhdp1I>
5. **Clase 5 :**
<https://youtu.be/ZDaXXdcc08E>
6. **Clase 6 :**
<https://youtu.be/BZktSbYHHnw>
7. **Clase 7 :**
<https://youtu.be/KoMf2RcCXM4>