

Laboratorio 1: Muestreo aleatorio simple

Fernanda Alvarado-Leitón

Introducción

Este laboratorio tiene como objetivo mostrar la utilización del software R para la selección de muestras aleatorias simples y la estimación de parámetros poblacionales. Recuerden que los pasos para la selección de una muestra aleatoria simple y la estimación de los parámetros poblacionales son:

- Cálculo del tamaño de muestra n (lo cubriremos más adelante).
- Conseguir o crear un marco muestral adecuado para la selección de las unidades de estudio.
- Identificar cada unidad de muestreo de manera única en el marco muestral.
- Seleccionar “ n ” números aleatorios.
- Identificar las unidades del marco muestral representadas por los números aleatorios seleccionados.
- Recolectar la información deseada de las unidades de estudio seleccionadas.
- Estimar los parámetros poblacionales (estimación puntual)
- Estimar los intervalos de confianza (estimación por intervalo)

Para la parte de estimación de parámetros, utilizaremos el paquete del programa *survey*. Si este paquete no está instalado en su computador inicie con la instalación del mismo utilizando el comando `install.packages("survey")` respectivamente. La documentación de cada uno de los paquetes de R puede ser consultada en: <https://cran.r-project.org/web/packages/>.

Problema: En el país de Mesopotamia, la provincia de Asiria desea construir un tren de pasajeros que la conecte con la provincia de Babilonia debido al importante número de trabajadores que se desplazan entre las dos provincias diariamente. Para poder pedir fondos al gobierno de Mesopotamia para la construcción del ferrocarril, el gobierno local de Asiria debe demostrar que al menos 1200 personas harían uso del tren. El gobierno de Asiria nos contrata para cumplir con este requisito. Como punto de partida el gobierno local brinda los datos de un conteo de los hogares realizado en cada municipio de la provincia en 2018 para la organización del recurso hídrico. La base de datos disponible (marco2b) cuenta con la siguiente información para cada vivienda: zona (urbana o rural), número de aposentos (variable `qapostos`), número de cuartos solo para dormir (`qcuartosdormir`) y consecutivo (identificador de las viviendas).

Parte 1. El marco muestral

Utilizando el archivo del conteo de 2018 como marco muestral, obtenga el número de viviendas en la provincia en el 2018.

Nota: configure la carpeta en la que descargó los datos del laboratorio como el directorio de trabajo usando el comando `setwd("direccion.carpeta")`.

```
load("marco2r.Rdata")
nrow(marco2r) #numero de registros en la base de datos
```

R/. En el 2018 en la provincia de Asiria habían _____ viviendas.

Parte 2. El identificador

Utilizando el mismo archivo, compruebe que cada vivienda tiene un identificador único.

```
length(unique(marco2r$consecutivo))
```

R/. Hay un consecutivo único para cada vivienda en la base de datos: Sí () No ().

Parte 3. Números aleatorios

Para la selección de números aleatorios se utiliza la función `sample` que tiene los siguientes parámetros:

`sample(x= vector, size = n, replace= TRUE/FALSE, prob= NULL/vector)`

- `x`: vector que contiene todos los números posibles a seleccionar (del mismo tamaño que el número de unidades de muestreo en el marco)
- `n`: número de elementos a seleccionar
- `replace`: si el procedimiento de muestreo debe ser con (TRUE) o sin (FALSE) reemplazo.
- `prob`: vector que contiene las probabilidades de selección de cada unidad de muestreo. Se especifica como NULL si todas las unidades tienen la misma probabilidad de selección.

¿Cuáles serían los consecutivos de las viviendas seleccionadas si se desea recolectar información de 800 viviendas? Nota: Utilice la función `set.seed()` antes de realizar la selección para poder tener trazabilidad de la selección.

```
num.posibles <- seq(1:nrow(marco2r))
set.seed(123)
muestra <- sample(num.posibles, size= 800, replace= FALSE); head(muestra)
```

Parte 4. La encuesta

Usando la lista de los hogares seleccionados el gobierno de Asiria realizó una encuesta en la que recolectó para cada vivienda:

- `thombres`: número de hombres de más de 18 años residiendo en la vivienda. - `totmujeres`: número de mujeres de más de 18 años residiendo en la vivienda. - `labora`: número de personas en el hogar que laboran en Babilonia.

Los datos de la encuesta se encuentran en el archivo `encuesta.asiria.RData`.

Usando el archivo de la muestra obtenga:

1. El número de hogares en la muestra
2. El número de personas en las viviendas entrevistadas que trabajan en Babilonia
3. El número de hogares en la muestra con al menos una persona trabajando en Babilonia

Nota: La base de datos de la muestra contiene además la información que estaba disponible en el marco muestral.

```
load("encuesta.asiria.RData")
nrow(encuesta) #numero de viviendas entrevistadas
sum(encuesta$labora) #numero de personas que laboran en Babilonia
library(dplyr)
encuesta <- encuesta %>% mutate(almenos = ifelse(labora >=1, 1, 0))
sum(encuesta$almenos) #numero de viviendas con al menos una persona laborando en Babilonia
```

R/. El número de viviendas entrevistadas fue _____.

El número de personas en las viviendas entrevistadas que trabajan en Babilonia fue _____.

El número de viviendas en la muestra con al menos una persona trabajando en Babilonia _____.

Parte 4. La inferencia puntual

Para saber si se justifica la construcción del ferrocarril, se necesita saber cuántas personas en Asiria trabajan en Babilonia. Para esto necesitamos utilizar los datos de la encuesta para hacer inferencia a la población. Las inferencias se pueden realizar utilizando el paquete *survey* y se realizan en dos pasos:

- indicarle al computador cómo se seleccionó la muestra y de qué (tamaño) población (declarar el diseño). - realizar la estimación usando el comando adecuado.

Para declarar el diseño se utiliza el comando `svydesign` que tiene los siguientes parámetros:

- `ids`: identificador de la unidad *de muestreo* en el archivo de la encuesta.
- `data`: archivo de datos de la encuesta.
- `fpc`: tamaño de la población (se recomienda que esté contenido en la base de datos).

Nota: En el paquete *survey* la inclusión del símbolo “~” antes del nombre de las variables indica la pertenencia al conjunto de datos. Cuando en la base de datos cada fila representa una unidad de muestreo el identificador se puede especificar como ~1.

```
encuesta$N <- nrow(marco2r)
library(survey)
diseño <- svydesign(ids=~1, data= encuesta, fpc= ~N)
```

Con el diseño definido estimar:

- El número de viviendas en Asiria.
- El número de personas en Asiria que laboran en Babilonia. - El número de viviendas en Asiria con al menos una persona trabajando en Babilonia.

Existen varios comandos en el paquete *survey* para realizar estimaciones (`svytotal`, `svymean`, `svyreg`, `svyby`, etc). `Svytotal` y `svymean` tienen los siguientes parámetros:

- variable a estimar: ~nombre.variable.
- diseño de la encuesta: nombre.diseño.

Nota: La inferencia implica que cada vivienda “representa” F viviendas. En este caso, cada vivienda en la muestra representa a $F = 11224/800 = 14.03$ viviendas en la población. Para obtener el número de viviendas en la población podemos tomar dos caminos: 1) sumar F para todas las unidades de la muestra ($800 * 11224/800 = 11224$) o crear una variable que contenga 1s y estimar el total (se muestra abajo)

```
diseño <- update(diseño, vivienda=1)
svytotal(~vivienda, diseño) #qué nos dice el SE?
svytotal(~labora, diseño)
svytotal(~almenos, diseño)
```

Basándose en los resultados obtenidos, ¿puede el gobierno local de Asiria pedir los fondos para la construcción del ferrocarril entre Asiria y Babilonia? ¿Por qué?

Parte 5. La inferencia por intervalo

Sabemos que las estimaciones puntuales del número de personas que trabajan en Babilonia y el número de hogares en los que al menos una persona labora en Babilonia dependen de la muestra seleccionada y pueden variar si otras viviendas se hubieran seleccionado en la muestra. Por esta razón, brindamos intervalos de confianza para mostrar la incertidumbre alrededor de las estimaciones. En R usamos el comando `confint` para calcular los intervalos de confianza, este comando tiene los siguientes parámetros:

- estimación: objeto que contiene la estimación para la cual se requiere el intervalo.
- `df`= grados de libertad para la estimación, se puede obtener con el comando `degf(nombre.diseño)`.
- `level`= nivel de confianza de la estimación (si no se especifica el default es 95%).

```
est.labora <- svytotal(~labora, diseno)
est.almenos <- svytotal(~almenos, diseno)
confint(est.labora, level = 0.90, df= degf(disen))
confint(est.almenos, level = 0.90, df= degf(disen))
```

¿Qué significa este intervalo?

Parte 6. Práctica individual

1. Estimar el número promedio de personas que trabajan en Babilonia por hogar y su intervalo de confianza (95% confianza). Nota: Utilizar solamente aquellos hogares para los cuales hay al menos una persona laborando en Babilonia.

```
media <- svymean(~labora, subset(disen, labora>0)); media
confint(media, df= degf(subset(disen, labora>0)))
```

2. Estimar *el porcentaje* de hogares con al menos una persona laborando en Babilonia para la zona urbana y rural. ¿Hay una diferencia significativa entre las zonas en el porcentaje de hogares por zona?

```
props <- svyby(~almenos, by= ~zona, diseno, FUN= svymean); props*100
confint(props, df= degf(disen))*100
```