

Laboratorio 2: Muestreo aleatorio estratificado y sistemático

Fernanda Alvarado-Leitón

1. Introducción

Este laboratorio tiene como objetivo mostrar la utilización del software R para la selección de muestras aleatorias estratificadas, sistemáticas y la estimación de parámetros poblacionales. Recuerden que los pasos para la selección de una muestra aleatoria y la estimación de los parámetros poblacionales son:

- Cálculo del tamaño de muestra n .
- Conseguir o crear un marco muestral adecuado para la selección de las unidades de estudio.
- Identificar cada unidad de muestreo de manera única en el marco muestral.
- Seleccionar “ n ” números aleatorios.
- Identificar las unidades del marco muestral representadas por los números aleatorios seleccionados.
- Recolectar la información deseada de las unidades de estudio seleccionadas.
- Estimar los parámetros poblacionales (estimación puntual)
- Estimar los intervalos de confianza (estimación por intervalo)

Para la parte de estimación de parámetros, utilizaremos el paquete del programa *survey*. Si este paquete no está instalado en su computador inicie con la instalación del mismo utilizando el comando `install.packages("survey")` respectivamente. La documentación de cada uno de los paquetes de R puede ser consultada en: <https://cran.r-project.org/web/packages/>.

2. Cálculo de tamaño de muestra

- a) Se va a realizar un estudio en el que se quiere estudiar el endeudamiento en tarjetas de crédito en un vecindario dividido en tres estratos: viviendas independientes, apartamentos (en edificios pequeños) y torres de apartamentos. Se sabe que la variable que se desea medir (deuda en tarjeta de crédito por hogar) se relaciona con el tipo de hogar (estrato).

En un estudio realizado en el vecindario hace tres años se obtuvo que en promedio los hogares tenían una deuda promedio de 235 000 colones, y que la desviación estándar de los montos era de 200 000 colones. En ese momento, la muestra del estudio comprendió 100 hogares.

En comparación de un mia y con la estratificación realizada, se espera que la variancia de la media se reduzca en 6%. ¿Qué tamaño de muestra se requiere para obtener un CV de la media de 0.1? Tome en cuenta que en el vecindario hay 500 hogares.

```
library(PracTools)
c <- 200000/235000; c
```

```
## [1] 0.8510638
```

```
n0 <- nCont(CV0=0.1, CVpop= c); n0
```

```
## [1] 72.43096
```

```
n0/500
```

```
## [1] 0.1448619
```

```
n <- nCont(CV0=0.1, CVpop= c, N=500); n
```

```
## [1] 63.26611
```

```
n.strat <- n*0.96
ceiling(n.strat)
```

```
## [1] 61
```

- b) Suponiendo un tamaño de muestra de 60 viviendas: reparta la muestra a los estratos usando afijación proporcional, de Neyman, óptima e igualitaria. Utilice la siguiente información:

Número de viviendas por estrato: 130 independientes, 160 aptos edificios pequeños, 210 torre de apartamentos. Deuda promedio: 270 000 independientes, 180 000 aptos edificios pequeños, 240 000 torre de apartamentos. Desviación estándar: 38 200 independientes, 23 000 aptos edificios pequeños, 67 500 torre de apartamentos. Costo de recolección por estrato: 7 500 independientes, 6 000 aptos edificios pequeños, 6 000 torre de apartamentos.

```
library(PracTools)
Nh <- c(130, 160, 210)
ybarh <- c(270000, 180000, 240000)
desvh <- c(38200, 23000, 67500)
costoh <- c(7500, 6000, 6000)

prop <- strAlloc(n.tot= 60, Nh= Nh, alloc= "prop"); prop #proporcional
ney <- strAlloc(n.tot= 60, Nh= Nh, Sh= desvh, alloc= "neyman"); ney #neyman

vec.opt <- (Nh*desvh/sqrt(costoh)); vec.opt
opt <- 60* vec.opt/sum(vec.opt); opt

igual <- 60/3; igual
```

3. Selección

Para seleccionar una muestra de los 600 hoteles existentes en la Península de Nicoya, el Instituto Costarricense de Turismo proporciona una lista numerada de los hoteles, ordenados según su tamaño (número de habitaciones). Un muestrista recomendó que se seleccionaran 48 hoteles para realizar un estudio sobre el costo diario de las habitaciones. a) Calcule el intervalo de muestreo para la selección de la muestra. b) Suponiendo que el arranque aleatorio fue 02 liste los números que identifican a los primeros 5 hoteles seleccionados. Usando el archivo “hoteles_peninsula_nicoya.xlsx” de el nombre de los primeros 5 hoteles seleccionados y sus números de teléfono.

```
k=600/48
k #a

k.prima <- k*10
k.prima

sels <- c(2, 2+k.prima, 2+2*k.prima, 2+3*k.prima, 2+4*k.prima, 2+5*k.prima, 2+6*k.prima)
sels
sels2 <- trunc(sels/10)
sels2 <- sels2[2:6] #b

library(readxl)
marco.muestral <- read_excel("hoteles_peninsula_nicoya.xlsx")
library(sampling)
```

```
sels3 <- rep(0,600)
sels3[sels2] <-1
primeros5 <- getdata(marco.muestral, sels3)
```

4. Estimación puntual, de la variancia del estimador y de intervalo

Muestreo estratificado

Se seleccionó una muestra mia estratificada en zonas montañosas, de ciudad y en las costas, para cuantificar el número de miembros por vivienda que padeció dengue en los últimos 12 meses. La información recolectada se encuentra en el archivo “lab2_datos.xlsx”. Se solicita lo siguiente: a) Calcule el intervalo de confianza para el promedio de personas por vivienda que ha padecido dengue en los últimos 12 meses en las tres zonas. b) Calcule el intervalo de confianza para el total de personas que ha padecido dengue en las tres zonas. c) ¿Existe diferencia entre el promedio de personas por vivienda con dengue entre las costas y las montañas?

```
library(readxl); library(tidyr); library(survey); library(dplyr)
datos <- read_excel("lab2_datos.xlsx")

datos <- datos[1:30, ]
datos <- gather(datos, key= "estrato", value= "casos", ~Vivienda) #reestructurando los datos
datos <- datos %>% mutate(Nh= case_when(estrato=="Montaña" ~ 135000,
                                       estrato== "Ciudad" ~ 105000,
                                       estrato== "Costas" ~ 60000, .default = 999)) %>%
  mutate(fh= 30/Nh) %>% mutate(wh= 1/fh)

disenyo <- svydesign(ids = ~1, strata = ~estrato, data= datos, weights = ~wh)

#punto a
media <- svymean(~casos, disenyo)

degf(disenyo)
confint(media, df=degf(disenyo))

#punto b
total <- svytotal(~casos, disenyo)
confint(total, df=degf(disenyo))

#punto c
media.estrato <- svyby(~casos, by= ~estrato, design = disenyo, FUN= svymean)
confint(media.estrato, df=degf(disenyo))
```

Sistemático

Para seleccionar una muestra de los 600 hoteles existentes en la Península de Nicoya, el Instituto Costarricense de Turismo proporciona una lista numerada de los hoteles, ordenados según su tamaño (número de habitaciones). Un muestrista recomendó que se seleccionaran 48 hoteles para realizar un estudio sobre el costo diario de las habitaciones. c) Suponga que los siguientes son los precios por noche (en dólares) para los hoteles seleccionados:

890, 849, 830, 769, 750, 710, 700, 699, 680, 649, 649, 649, 625, 619, 615, 615, 599, 599, 599, 599, 578, 569, 569, 519, 510, 500, 499, 499, 449, 420, 399, 399, 349, 349, 349, 330, 318, 300, 299, 279, 249, 249, 249, 230, 230, 199, 199, 150.

```
precios <- c(890, 849, 830, 769, 750, 710, 700,
            699, 680, 649, 649, 649, 625, 619,
```

```

615, 615, 599, 599, 599, 599, 578,
569, 569, 519, 510, 500, 499, 499,
449, 420, 399, 399, 349, 349, 349,
330, 318, 300, 299, 279, 249, 249,
249, 230, 230, 199, 199, 150)
media <- mean(precios)
media #d

dif2= c()
n= length(precios)
h=1; i=1
while(i < n) {
dif2[h]= (precios[i]-precios[i+1])^2
h= h+1
i=i+2
}

sumadif2 <- sum(dif2)
var <- (1-(48/600))*sumadif2/n^2; var #e, porque la lista esta
#ordenada por precios y el tamaño de muestra es par

li<- media - qt(0.975, n/2)*sqrt(var); li
ls <- media + qt(0.975, n/2)*sqrt(var); ls#f

var.srs <- (1-(48/600))* var(precios)/n
deff = var/var.srs
deff #g

#La variancia se redujo en un 99% al utilizar una muestra
#sistemática en lugar de una aleatoria. (Aquí el efecto es muy
#claro por el orden que tenía la lista)

total <-15000*media
total #h

```