

# Laboratorio 3: Muestreo aleatorio de conglomerados iguales completos y con submuestreo

Fernanda Alvarado-Leitón

## 1. Introducción

Este laboratorio tiene como objetivo mostrar la utilización del software R para la selección de muestras aleatorias de conglomerados iguales, completos o con submuestreo y la estimación de parámetros poblacionales. Recuerden que los pasos para la selección de una muestra aleatoria y la estimación de los parámetros poblacionales son:

- Cálculo del tamaño de muestra  $n$ .
- Conseguir o crear un marco muestral adecuado para la selección de las unidades de estudio.
- Identificar cada unidad de muestreo de manera única en el marco muestral.
- Seleccionar “ $n$ ” números aleatorios.
- Identificar las unidades del marco muestral representadas por los números aleatorios seleccionados.
- Recolectar la información deseada de las unidades de estudio seleccionadas.
- Estimar los parámetros poblacionales (estimación puntual)
- Estimar los intervalos de confianza (estimación por intervalo)

Para la parte de estimación de parámetros, utilizaremos el paquete del programa *survey*. Si este paquete no está instalado en su computador inicie con la instalación del mismo utilizando el comando `install.packages("survey")` respectivamente. La documentación de cada uno de los paquetes de R puede ser consultada en: <https://cran.r-project.org/web/packages/>.

## 2. Cálculo de tamaño de muestra

Suponga que es noviembre de 2020. Un crucero con 419 pasajeros adultos provenientes de Europa se dirige hacia el Caribe costarricense. Dos días antes de atracar 3 pasajeros presentaron síntomas de COVID-19. Para evitar más contagios entre pasajeros y las personas en la comunidad destino se tomaron las siguientes decisiones: 1. Se aislaron en el crucero las tres personas con síntomas. 2. El resto de pasajeros y la tripulación se ubicó en cuarentena en un hotel cercano al puerto. La distribución de los pasajeros en las habitaciones se realizó de la siguiente forma: 2.1. Los pasajeros fueron alojados en las habitaciones del hotel de acuerdo al tipo de paquete que habían reservado para el crucero (Lux o Standard). 2.2. La tripulación se alojó en habitaciones aparte de los pasajeros. 2.3. En cada habitación se alojaron 4 personas.

Debido a la saturación de servicios de salud en el país y la escasez de pruebas PCR el Ministerio de Salud decide estimar la proporción de posibles casos para preparar los recursos y el personal necesario para atender los pacientes. Si se desea que el error estándar sea de máximo 4% y se asume que  $\rho$  para  $p$  es 0.19. Calcule  $n$  y proponga dos diseños (uno de conglomerados completos y otro con submuestreo) que cumplan con la precisión deseada.

```
#quitar a las personas que estan aisladas
library(PracTools)
p <- 0.5
N <- 459-3
(n.mia <- nProp(V0= 0.04^2, pU=0.5, N=N))
(n.comp <- n.mia*(1+(4-1)*0.19))
(a.comp <- ceiling(n.comp/4))
```

```
(n.sub <- n.mia*(1+(2-1)*0.19))
(a.sub <- ceiling(n.sub/2))
```

### 3. Selección

3.1. Suponga que se van a seleccionar 40 habitaciones y dentro de cada una se realizará la prueba de COVID a todas las personas. El archivo “manifiesto.Rdata” contiene el nombre, el país de origen, tipo de paquete (Standard, Lux, Tripulación) y el número de habitación para cada persona en el crucero. Los nombres de las personas estas personas son: Jakub Król, Paul Martin y Sandrine Laurent. Genere una tabla con el número de habitación y los nombres de las personas seleccionadas en la muestra.

```
library(sampling)
manifiesto2 <- subset(manifiesto,
                      Name %in% c("Jakub Król",
                                   "Paul Martin",
                                   "Sandrine Laurent")==FALSE)

set.seed(456)
seleccion1<-sampling::cluster(manifiesto2,
                              clustername=c("Room"), size=40,
                              method="srswor", description=TRUE)

muestra1 <- getdata(manifiesto2, seleccion1)
```

3.2. Suponga que se van a seleccionar 70 habitaciones y dentro de cada una se realizará la prueba de COVID a dos de las personas en la habitación. El archivo “manifiesto.Rdata” contiene el nombre, el país de origen, tipo de paquete (Standard, Lux, Tripulación) y el número de habitación para cada persona en el crucero. Los nombres de las personas estas personas son: Jakub Król, Paul Martin y Sandrine Laurent. Genere una tabla con el número de habitación y los nombres de las personas seleccionadas en la muestra.

```
set.seed(232)
seleccion2<-sampling::mstage(manifiesto2, stage= c("cluster", ""),
                             varnames = list("Room", "Name"),
                             size= list(70, c(rep(2,70))),
                             method= list("srswor", "srswor"))

muestra2 <- getdata(manifiesto2, seleccion2[[2]])
dim(muestra2)
n_distinct(muestra2$Room)
n_distinct(muestra2$Name)
```

### 4. Estimación

El archivo “covid.Rdata” contiene la información de los resultados de las pruebas de COVID. Utilizando la variable “covid” (0=prueba negativa, 1= prueba positiva), estime el porcentaje de personas con una prueba positiva y su intervalo de confianza (95%).

```
library(survey)
load("covid.Rdata")

disenyo <- svydesign(id=~Room, data=covid)

## Warning in svydesign.default(id = ~Room, data = covid): No weights or
## probabilities supplied, assuming equal probability
```

```
(prop <- svymean(~covid, disenyo))  
(svyciprop(~covid, disenyo, method="logit"))
```