

Laboratorio 4: Muestreo aleatorio de conglomerados desiguales

Fernanda Alvarado-Leitón

1. Introducción

Este laboratorio tiene como objetivo mostrar la utilización del software R para la selección de muestras aleatorias de conglomerados desiguales, completos o con submuestreo y la estimación de parámetros poblacionales. Recuerden que los pasos para la selección de una muestra aleatoria y la estimación de los parámetros poblacionales son:

- Cálculo del tamaño de muestra n .
- Conseguir o crear un marco muestral adecuado para la selección de las unidades de estudio.
- Identificar cada unidad de muestreo de manera única en el marco muestral.
- Seleccionar “ n ” números aleatorios.
- Identificar las unidades del marco muestral representadas por los números aleatorios seleccionados.
- Recolectar la información deseada de las unidades de estudio seleccionadas.
- Estimar los parámetros poblacionales (estimación puntual)
- Estimar los intervalos de confianza (estimación por intervalo)

Para la parte de estimación de parámetros, utilizaremos el paquete del programa *survey*. Si este paquete no está instalado en su computador inicie con la instalación del mismo utilizando el comando `install.packages("survey")` respectivamente. La documentación de cada uno de los paquetes de R puede ser consultada en: <https://cran.r-project.org/web/packages/>.

1. Diseño 1: Muestreo de conglomerados desiguales *completos*

En un proyecto de la universidad se desea conocer el sobre el conocimiento y la opinión de estudiantes de la ucr en el tema de edición de genomas mediante la técnica CRISPR/Cas9. Para cumplir con este objetivo se realizó una encuesta dirigida a estudiantes de pregrado y grado de la sede Rodrigo Facio en el I ciclo de 2018. El marco muestral para seleccionar la muestra fue un archivo con todos los grupos activos de grado y posgrado (UPM), la matrícula actual y el área, la facultad, la escuela y el curso al que pertenece cada grupo.

El archivo *muestraucr.RData* contiene los resultados de la encuesta aplicada al estudiantado. Usando este archivo:

- a. Identifique el número de grupos (conglomerados) y las entrevistas realizadas por grupo (estudiantes).

```
library(dplyr)
load("muestraucr.Rdata")

#numero de grupos
n_distinct(muestraucr$UPM)

#numero de estuidantes por grupo
muestraucr <- muestraucr %>% group_by(UPM) %>% mutate(balpha= n())
table(muestraucr$balpha)
```

- b. Defina el diseño de la muestra usando el comando `svydesign`. ¿Qué tipo de estimador utilizará R para analizar los datos? ¿Por qué?

```
library(survey)
diseno1 <- svydesign(ids = ~UPM, data = muestraucr, weights = ~PONDERADOR)
```

- c. Calcule la proporción y el intervalo de confianza (svyciprop) para las respuestas a las categorías de la variable “EG2”, ¿cuánto ha escuchado sobre la edición genética con la técnica CRISPR/Cas9, mucho, algo, poco o nada?.

```
library(janitor)
tabyl(muestraucr$EG2)
muestraucr <- muestraucr %>% mutate(EG2= factor(EG2, levels= c(0,1,2,3),
                                                labels= c("nada", "poco",
                                                            "algo", "mucho")))
diseno1 <- svydesign(ids = ~UPM, data = muestraucr, weights = ~PONDERADOR)
(prop <- svymean(~EG2, diseno1, na.rm = T))
svyciprop(~I(EG2=="nada"), diseno1, method = "logit", df=degf(diseno1))
svyciprop(~I(EG2=="poco"), diseno1, method = "logit", df=degf(diseno1))
svyciprop(~I(EG2=="algo"), diseno1, method = "logit", df=degf(diseno1))
svyciprop(~I(EG2=="mucho"), diseno1, method = "logit", df=degf(diseno1))
```

- d. ¿Difiere el porcentaje de estudiantes que ha escuchado (mucho+algo+poco) sobre la edición genética por sexo (CS1)?

```
muestraucr <- muestraucr %>% mutate(escuchado=
                                     case_when(EG2=="poco" | EG2=="algo"
                                                | EG2== "mucho" ~ 1,
                                                EG2== "nada" ~ 0, .default=NA))

diseno1 <- svydesign(ids = ~UPM, data = muestraucr, weights = ~PONDERADOR)
(pxs <- svyby(~escuchado, by= ~CS1, diseno1, na.rm = T, FUN = svymean))

svyciprop(~I(escuchado==1), subset(diseno1, CS1==1), method = "logit", df=degf(diseno1))
svyciprop(~I(escuchado==1), subset(diseno1, CS1==2), method = "logit", df=degf(diseno1))
```

2. Diseño 2: Muestreo de conglomerados desiguales con submuestreo y f_b fija

En un cantón de la provincia de Cartago se quiere realizar una encuesta a personas de 55 años y más para conocer quiénes y a qué edad han sido diagnosticados con depresión. Para la recolección de los datos se utiliza muestreo de áreas (se divide el mapa de la provincia en UPMs), seleccionando 26 UPMs de las 204 totales con igual probabilidad y dentro de cada una se submuestra con una décima parte de cada UPM. El archivo **muestra5.Rdata** contiene los datos recolectados en esta operación estadística. Usando ese archivo:

- a. Calcule el tamaño (B_α) de cada UPM seleccionada

```
load('muestra5.Rdata')
muestrab <- muestrab %>% group_by(psuid) %>% mutate(b=n())
muestrab <- muestrab %>% mutate(B= b*10)
muestrab %>% group_by(psuid) %>% summarise(sub= mean(b))
```

- b. ¿El diseño muestral utilizado es mesip?

- c. Estime el porcentaje de personas mayores a 55 años en la provincia que han sido diagnosticadas con depresión.

```
muestrab <- muestrab %>% mutate(f= (26/204)*(b/B)) %>% mutate(w= 1/f)
summary(muestrab$w)
diseno2 <- svydesign(ids = ~psuid, data = muestrab, weights= ~w)
(dep<- svymean(~depressed, design = diseno2, na.rm = T))
```

3. Diseño 3: Muestreo de conglomerados desiguales con submuestreo y b fija

Para conocer el nivel en cálculo del estudiantado en una universidad se seleccionan con igual probabilidad 13 de las 187 clases de cálculo que se imparten en la institución. En cada una de las clases se seleccionan con igual probabilidad 5 estudiantes que realizaron una prueba diagnóstica en cálculo. El archivo *calculo.Rdata* contiene el número de grupo (grupo), el número de estudiantes matriculados en cada grupo (matricula), el número de estudiante seleccionado en cada grupo (estudiante) y la nota obtenida en el examen diagnóstico (notas). Utilizando el archivo brindado: a. Obtenga la probabilidad de selección en la muestra para cada estudiante. ¿La muestra es mesip? b. Calcule el ponderador necesario para hacer inferencia a la población de estudiantes que se encuentran matriculados en un curso de cálculo en la universidad.

```
load('calculo.Rdata')
calculo <- calculo %>% mutate(fa= 13/187) %>%
  mutate(fb=5/matricula) %>%
  mutate(f=fa*fb) %>% mutate(w=1/f)
summary(calculo$f)
```

c. ¿Cuántos estudiantes se encuentran matriculados en un curso de cálculo en la universidad?

```
calculo <- calculo %>% mutate(cant= 1)
diseno3 <- svydesign(ids = ~grupo, data= calculo, weights=~w)
(total <- svytotal(~cant, diseno3))
```

d. ¿Cuál es la calificación promedio del estudiantado en la prueba diagnóstica?

```
(promedio <- svymean(~notas, diseno3))
```

e. ¿Cuántos estudiantes en la universidad manejan un nivel de cálculo satisfactorio (obtendrían al menos un 60 en el examen)?

```
calculo <- calculo %>% mutate(mas60= case_when(notas >=60 ~1,
                                              notas <60 ~ 0, .default = NA))
diseno3 <- svydesign(ids = ~grupo, data= calculo, weights=~w)
(total2 <- svytotal(~I(mas60==1), diseno3))
```

4. Diseño 4: Muestreo de conglomerados desiguales con probabilidad de selección proporcional al tamaño.

Se realizó en el país una encuesta de 1200 viviendas para conocer el porcentaje de hogares con vehículo (no de trabajo). El diseño muestral fue bi-etápico: en la primera etapa se seleccionaron segmentos de mapa (pcds) de acuerdo al número de hogares en el segmento. En la segunda etapa se seleccionaron 5 viviendas en cada PCD. Utilizando el archivo *muestra1.Rdata*: a. ¿Cuántas UPMs se seleccionaron en la muestra?

```
load('muestra1.Rdata')
n_distinct(muestra1$pcds)
```

b. Si en el marco muestral habían 10064 UPMs, ¿Cuál es la probabilidad de selección de cada UPM en la primera etapa?

```
load('muestra1.Rdata')
muestra1 <- muestra1 %>% mutate(fa = 240/10064)
```

c. ¿Cuál es la probabilidad de selección de cada elemento en la segunda etapa?

d. ¿Es este diseño mesip?

```
muestra1 <- muestra1 %>% mutate(fb = 5/mt) %>% mutate(f= fa*fb)
summary(muestrab$f)
```

e. Estime el total de hogares en el país que tienen al menos un vehículo (no de trabajo).

```
muestra1 <- muestra1 %>% mutate(w= 1/f)  
diseno4 <- svydesign(ids= ~idupm, data= muestra1, weights = ~w)  
svytotal(~carro, design = diseno4)
```