

Resumen: supuestos del modelo, potencia y análisis de covariancia

Kendall Martínez

Índice

1	El error y el residuo: la base de todo	3
2	Independencia de los errores	4
3	Normalidad	5
3.1	Definición formal e intuitiva	5
3.2	Verificación gráfica: QQ-plot	5
3.3	Prueba de Kolmogorov–Smirnov	5
3.4	Prueba de Shapiro–Wilk	6
4	Homocedasticidad	7
4.1	Definición formal e intuitiva	7
4.2	Verificación gráfica	7
4.3	Pruebas formales	8
5	El árbol completo: cómo evaluar normalidad según homocedasticidad	8
6	Tabla espejo: métodos paramétricos vs. no paramétricos	10
6.1	Prueba de Jonckheere–Terpstra	10
6.2	ANDEVA no paramétrico de Friedman	10
7	Prueba de interacción con contraste de rangos alineados	10
8	Prueba de permutaciones con simulaciones	12
9	Bootstrap: parecidos y diferencias con las permutaciones	12
10	Soluciones ante violaciones de supuestos	14
10.1	Mínimos cuadrados ponderados (WLS)	14
10.2	Transformaciones de la respuesta	15
11	Diferencia relevante y potencia	15
11.1	¿Qué tan diferente es “diferente”?	15
11.2	Error tipo II y potencia	15

12 Estudios de simulación para calcular potencia	16
12.1 Lógica general	16
12.2 Código en R: simulación de potencia para un factor	17
12.3 Atajo analítico: la función <code>power.anova.test</code>	18
12.4 Extensión a diseños factoriales	19
12.5 Extensión a diseños con bloques	21
13 Análisis de covariancia (ANCOVA)	21
13.1 Motivación	21
13.2 Modelo con covariables	22
13.3 Comparación condicional de promedios	22
13.4 Por qué importa mirar un intervalo pequeño de la covariable	23
13.5 Análisis formal: separar la variabilidad de la covariable	23
13.6 Verificación formal del supuesto de paralelismo	24
13.7 Comparación de tratamientos cuando no hay paralelismo	25
13.8 Ejemplo: carrera de 100 metros	26
14 Flujo de análisis completo	28

1 El error y el residuo: la base de todo

Antes de hablar de normalidad u homocedasticidad hace falta separar dos distancias que a simple vista parecen lo mismo, pero que conceptualmente no lo son.

Error vs. residuo

- **Error** (ε): la distancia de la observación y a la **media condicional poblacional** μ_j . Es un objeto teórico, nunca lo observamos directamente.

$$\varepsilon_{ij} = y_{ij} - \mu_j.$$

- **Residuo**: la distancia de la observación a la **media muestral** $\bar{y}_j$ (la estimación de μ_j con los datos que tenemos). Es lo que de verdad se calcula después de ajustar un modelo.

$$\hat{\varepsilon}_{ij} = y_{ij} - \bar{y}_j.$$

Por qué μ_j es una constante dentro del tratamiento

Dentro del tratamiento j , μ_j no varía: es un número fijo. Por eso restarlo a y_{ij} es como restarle una constante a una variable aleatoria, y ahí entra la propiedad de la varianza de una combinación lineal:

$$\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y) + 2ab\text{Cov}(X, Y).$$

Si $B = A - c$ con c constante, entonces $\text{Var}(B) = \text{Var}(A)$: restar una constante no cambia la varianza, solo desplaza la media.

De y_{ij} a ε_{ij} y viceversa

Como μ_j es constante, $\varepsilon_{ij} = y_{ij} - \mu_j$ es una traslación de y_{ij} :

$$\begin{aligned} y_{ij} \sim \mathcal{N} &\iff \varepsilon_{ij} \sim \mathcal{N}, & E[\varepsilon_{ij}] &= E[y_{ij}] - \mu_j = \mu_j - \mu_j = 0, \\ \text{Var}[y_{ij}] &= \sigma^2 \iff \text{Var}[\varepsilon_{ij}] = \sigma^2. \end{aligned}$$

Esta equivalencia es la razón por la cual da exactamente lo mismo evaluar normalidad y homocedasticidad sobre y condicionado al tratamiento, o sobre los residuos del modelo ajustado: son la misma pregunta vista desde dos lugares.

Ejemplo numérico de la traslación

Si $A \sim \mathcal{N}$ con $E[A] = \mu_A = 25$ y $B = A + 3$, entonces $E[B] = E[A] + 3 = 28$ y $\text{Var}[B] = \text{Var}[A + 3] = \text{Var}[A]$. Sumar o restar una constante mueve la media pero no toca la varianza. Por eso “centrar” los datos (restar la media de su bloque o tratamiento, como se hace al graficar diferencias entre catadores o bloques) nunca distorsiona la

forma de la distribución, solo la recentra.

2 Independencia de los errores

De los tres supuestos del modelo, la independencia es el más fácil de pasar por alto porque no tiene una prueba formal única asociada, pero es también el más grave de violar: si se incumple, ni los errores estándar ni los valores p del ANOVA clásico son válidos, sin importar qué tan bien se vean la normalidad y la homocedasticidad.

Qué exige el supuesto

Los errores ε_{ij} no deben estar correlacionados entre sí: el valor de una observación no debe dar información sobre el valor de otra, más allá de lo que ya explica el tratamiento al que pertenece.

Las dos fuentes más comunes de dependencia

- **Orden temporal o espacial de recolección:** si hay un efecto de aprendizaje, fatiga, o deriva del instrumento de medición a lo largo del tiempo, observaciones consecutivas tienden a parecerse entre sí más de lo que dictaría el azar. Se detecta graficando los residuos contra el orden (temporal o espacial) de recolección y buscando tendencias o agrupamientos sistemáticos, en vez de una nube de puntos sin patrón.
- **Estructura de bloques con varias unidades por combinación bloque-tratamiento:** cuando dentro de un mismo bloque hay más de una unidad recibiendo el mismo tratamiento, esas unidades comparten condiciones del bloque que no comparten con unidades de otros bloques, y sus respuestas terminan correlacionadas entre sí.

Por qué no hay una “prueba de independencia” estándar

A diferencia de normalidad (QQ-plot, Shapiro-Wilk, K-S) y homocedasticidad (Levene, Bartlett), la verificación de independencia depende del contexto específico de recolección de los datos: ¿hubo un orden? ¿hubo ubicaciones?, ¿hubo bloques con repeticiones? Por eso la herramienta principal sigue siendo gráfica y conceptual, basada en cómo se diseñó y ejecutó el experimento, más que en un estadístico de prueba único.

3 Normalidad

3.1 Definición formal e intuitiva

El supuesto pide que, dentro de cada tratamiento, la respuesta se distribuya normal:

$$Y | j \sim \mathcal{N}(\mu_j, \sigma^2) \iff \varepsilon_{ij} \sim \mathcal{N}(0, \sigma^2). \quad (1)$$

Intuición

No es que *todos* los datos juntos deban verse normales: es que, si uno se para dentro de un solo tratamiento y mira solo esos datos, la nube debe acumularse simétricamente alrededor de su media, sin colas pesadas ni valores que se disparen muy lejos. Tres distribuciones normales con medias distintas, vistas todas juntas sin separar por tratamiento, pueden parecer multimodales o sesgadas; eso no rompe el supuesto, porque el supuesto es **condicional** al tratamiento.

3.2 Verificación gráfica: QQ-plot

El QQ-plot ordena los residuos y los compara contra los cuantiles que se esperarían de una normal teórica. Si los puntos siguen la recta $y = x$, hay compatibilidad con la normalidad.




Figura 1: QQ-plot: la mayoría de los puntos sigue la recta de referencia; la cola superior se separa, indicando una posible asimetría o valores atípicos.

3.3 Prueba de Kolmogorov–Smirnov

H_0

Hay normalidad: las distancias **no condicionales** de la respuesta para cada tratamiento son normales.

$$p \begin{cases} p < 0.05 \Rightarrow \text{rechazo } H_0 \Rightarrow \text{estamos en problemas} \\ p > 0.05 \Rightarrow \text{no rechazo} \Rightarrow \text{asumo normalidad} \end{cases} \quad (2)$$

La potencia es lo opuesto al error tipo II

potencia $\xleftrightarrow{\text{opuesto}}$ error tipo II

Potencia	Error tipo II
Decir que no hay normalidad cuando en realidad no hay	Asumir normalidad cuando en realidad no hay

Con muestras grandes la prueba tiene mucha potencia y rechaza normalidad ante desviaciones mínimas que ni le importan al ANOVA (que es robusto). Con muestras pequeñas pasa lo contrario: poca potencia, alto riesgo de error tipo II, y se “asume normalidad” sin tener cómo verificarla bien. Por eso **nunca** se usa la prueba sola, siempre acompañada del QQ-plot.

3.4 Prueba de Shapiro–Wilk

Estadístico y H_0

La prueba de Shapiro–Wilk evalúa la misma H_0 que Kolmogorov–Smirnov (hay normalidad), pero con un estadístico distinto, construido a partir de la correlación entre los residuos ordenados y los cuantiles teóricos esperados bajo normalidad:

$$W = \frac{(\sum_{i=1}^n a_i \hat{\varepsilon}_{(i)})^2}{\sum_{i=1}^n (\hat{\varepsilon}_i - \bar{\hat{\varepsilon}})^2},$$

donde $\hat{\varepsilon}_{(i)}$ son los residuos ordenados y a_i son constantes que dependen de las varianzas, medias y covarianzas esperadas de los estadísticos de orden de una muestra normal estándar de tamaño n . Valores de W cercanos a 1 son compatibles con normalidad; mientras más se aleje de 1, más evidencia en contra.

Por qué se usa junto a K–S y no en su lugar

Shapiro–Wilk es, en general, **más potente** que Kolmogorov–Smirnov para detectar desviaciones de normalidad, especialmente en muestras pequeñas y moderadas, porque su construcción usa explícitamente la información de orden de *toda* la muestra en vez de comparar únicamente la distancia máxima entre funciones de distribución acumuladas (que es lo que hace K–S). En la práctica, ambas pruebas se corren **en conjunto** sobre los mismos residuos, junto con el QQ-plot: si las tres se contradicen entre sí, el QQ-plot manda, porque permite ver *en qué parte* de la distribución está el problema (una cola, un par de atípicos, asimetría general), algo que ninguna prueba formal por sí sola muestra.

Lectura comparativa

Si sobre los mismos residuos se obtiene $W = 0.815$ con $p = 0.0001$ (Shapiro–Wilk) y $D = 0.206$ con $p = 0.158$ (Kolmogorov–Smirnov), las dos pruebas no coinciden: Shapiro–Wilk rechaza con fuerza mientras que K–S no rechaza. Esta discrepancia es precisamente la situación típica en la que K–S, al ser menos potente, no detecta lo que Shapiro–Wilk sí detecta; el QQ-plot de esos mismos residuos suele mostrar el problema con claridad (por ejemplo, un par de observaciones muy alejadas de la recta de referencia), confirmando la lectura de Shapiro–Wilk.

4 Homocedasticidad

4.1 Definición formal e intuitiva

$$\text{Var}[Y | j] = \sigma^2 \quad \forall j \quad \Longleftrightarrow \quad \text{Var}[\varepsilon_{ij}] = \sigma^2 \quad \forall i, j. \quad (3)$$

Intuición

Cada distribución condicional de la respuesta debe tener la **misma forma**: mismo tipo de campana (normal), pueden diferir en media, pero **la misma varianza** en todos los tratamientos. Visualmente, si superponemos las tres curvas $Y|T_1$, $Y|T_2$, $Y|T_3$ desplazadas a lo largo del eje de tratamientos, deben verse igual de “anchas”.




Figura 2: Distribuciones condicionales con la misma varianza: mismo ancho de campana en cada tratamiento, solo cambia la posición (la media).

4.2 Verificación gráfica

Residuos vs. valores ajustados (o vs. tratamiento). Dispersión pareja a lo ancho del eje horizontal = homocedasticidad; nube en forma de abanico (se abre o se cierra) = heterocedasticidad.




Figura 3: Espectro de patrones en el gráfico de residuos vs. valores ajustados. De izquierda a derecha: dispersión prácticamente constante, un caso ambiguo donde la varianza crece levemente (frontera de decisión en la práctica), y un caso de heterocedasticidad evidente con forma de abanico.

4.3 Pruebas formales

- **Levene**: robusta ante violaciones de normalidad. H_0 : varianzas iguales.
- **Bartlett**: más potente, pero sensible a la normalidad; si no hay normalidad, da falsos positivos con facilidad.

5 El árbol completo: cómo evaluar normalidad según homocedasticidad

Esta es la pregunta que de verdad ordena todo el capítulo: *¿Cómo evaluar normalidad?* La respuesta depende de dos cosas a la vez: si hay o no homocedasticidad, y si el tamaño de muestra es grande o pequeño.




Figura 4: Árbol de decisión completo. Si hay homocedasticidad, el QQ-plot ya es confiable por sí solo. Si no hay homocedasticidad, el QQ-plot deja de ser confiable directamente: hay que mirar si, a pesar de eso, hay normalidad. Si la hay, se puede seguir. Si no la hay, “no se sabe nada” y la salida depende del tamaño de muestra: con r grande se puede verificar normalidad **tratamiento por tratamiento por separado**; con r pequeño no queda otra que un método no paramétrico.

La idea de fondo

Cuando r es grande, cada tratamiento por sí solo ya tiene suficientes datos para correr una prueba de normalidad confiable **usando solo esos datos**, sin mezclarlos con los residuos generales del modelo. Cuando r es pequeño, ningún tratamiento por separado tiene suficiente información, y mezclar los residuos de todos los tratamientos solo tiene sentido si efectivamente hay homocedasticidad (porque si las varianzas son distintas, mezclar residuos de tratamientos con dispersiones distintas no dice nada útil sobre la normalidad de ninguno).

Caso especial: muestra grande y normal pero sin homocedasticidad

Si hay normalidad confirmada por tratamiento y r es grande, **sí se puede usar ANOVA** aunque no haya homocedasticidad, siempre que se corrija el modelo (Sección 10.1). Lo que no se puede hacer es usar el ANOVA clásico de varianza única sin ajustar nada.

6 Tabla espejo: métodos paramétricos vs. no paramétricos

Comparación completa			
Paramétricas		No paramétricas	
H_0	Técnica	H_0	Técnica
$\mu_1 = \dots = \mu_K$	ANOVA (F), ANOVA Welch (heter.)	$\text{Med}_1 = \dots = \text{Med}_K$	Kruskal–Wallis (K-W)
$\mu_1 = \mu_2$	t , ANOVA (F)	$\text{Med}_1 = \text{Med}_2$	U de Mann–Whitney
Comparaciones por pares: Tukey		Pares $\times$ rangos no param.: K-W por pares	

El camino de Friedman

Cuando hay **bloques** y no se cumple normalidad, el camino no paramétrico continúa un paso más:

$$\text{Med}_1 = \text{Med}_2 = \text{Med}_3 \} \text{ bloque} \implies \text{Friedman.}$$

Es decir, Friedman es a Kruskal–Wallis lo que el diseño de bloques es al ANOVA de un factor: la versión que extrae la variabilidad de bloque antes de comparar medianas.

6.1 Prueba de Jonckheere–Terpstra

Más potente que Kruskal–Wallis y la prueba de la mediana cuando existe una **ordenación a priori** (ascendente o descendente) entre las poblaciones comparadas. Si el investigador ya sospecha un orden natural en los tratamientos (por ejemplo, dosis crecientes), aprovechar esa información da más potencia que tratar los grupos como intercambiables.

6.2 ANDEVA no paramétrico de Friedman

Compara las medianas de las distribuciones de cada tratamiento cuando estos se tomaron en forma de **bloque**. Evalúa un solo factor a la vez: ni Friedman ni Kruskal–Wallis manejan por sí solos el efecto **combinado** de dos factores. Para eso se recurre al método de la Sección 7.

7 Prueba de interacción con contraste de rangos alineados

Los métodos no paramétricos de un solo factor (Kruskal–Wallis, Friedman) no fueron pensados para examinar interacción entre dos factores a la vez, tal como lo señalan Wobbrock,

Findlater, Gergle y Higgins (2011), quienes formalizaron el método de rangos alineados. El camino estándar para resolver esto, es **alinear los rangos**: quitarle a cada observación lo que ya explican los efectos principales, y trabajar con lo que queda.

Alternativas más recientes – fuera del alcance del curso

Existen propuestas posteriores que prueban interacción de forma **más directa**, sin el paso previo de alineación: la prueba de pseudo-rangos de Gao y Alvo (2005), que compara la suma de rangos por fila contra la suma de rangos por columna, y los procedimientos APCSSA/APCSSM propuestos por Tran, Wagaman, Nguyen, Jacobson y Hartlaub (2024), ya implementados en paquetes de R como `WRS2` y `nparLD`. No se desarrollan aquí porque no se vieron en clase; se mencionan solo para que quede registro de que el método de rangos alineados **no es la única** solución disponible en la literatura, aunque sí sigue siendo el más usado y el más fácil de ejecutar a mano.

Transformación

$$y_{ij}^* = \widehat{(\alpha\beta)}_{ij} + r_{ij}, \quad (4)$$

donde $\widehat{(\alpha\beta)}_{ij}$ es el efecto de interacción estimado del modelo clásico y r_{ij} es el residuo de esa observación. Se ordena y_{ij}^* y se obtienen los rangos R_{ij} . Se corre un análisis de varianza **sobre los rangos**:

```
mod2 = lm(R ~ F1*F2).
```

Ejemplo numérico con 2×2

Con dos niveles en cada factor y dos réplicas por celda, se calcula $\widehat{(\alpha\beta)}_{ij}$ para cada combinación (en este caso, ± 0.625 según la celda), se suma el residuo correspondiente, y se obtiene el vector Y^* . Al ordenar esos ocho valores se obtienen los rangos:

$$R = (5.5, 7, 1, 2.5, 3.5, 2, 8, 5.5).$$

Al ajustar `lm(R~F1*F2)` sobre estos rangos se obtiene $p(\text{interacción}) = 0.31$, por lo que **no hay evidencia de interacción** según el modelo no paramétrico. Vale la pena comparar este resultado con el modelo clásico `mod1 = lm(y~F1*F2)`, que en este caso daba $p = 0.31$ también: ambos coinciden en no rechazar.

8 Prueba de permutaciones con simulaciones

Procedimiento

1. Se reasignan aleatoriamente los sujetos a cada grupo, **manteniendo el tamaño original** de cada uno.
2. Se calcula la diferencia de medias entre grupos para esa reasignación y se almacena.
3. Se repiten los pasos 1 y 2 un número alto de veces K .
4. El valor p es la proporción de permutaciones cuya diferencia absoluta es igual o mayor a la observada.

Por qué funciona sin supuestos

Si la hipótesis nula es cierta (no hay diferencia real entre grupos), entonces la etiqueta de grupo es arbitraria: cualquier reasignación de etiquetas debería producir una diferencia de medias parecida a la observada. Si la diferencia observada es muy rara comparada con las que se obtienen permutando al azar, eso es evidencia contra H_0 **sin necesidad de asumir ninguna forma distribucional**.

Ejemplo numérico

Diferencia observada: $|\bar{y}_1 - \bar{y}_2| = \text{obs} = 0.5$. Se generan $K = 4$ permutaciones con diferencias 2.5, 0.7, 0.2 y 0.1. De estas, solo dos (2.5 y 0.7) son mayores o iguales a la observada (0.5):

$$p = \frac{2}{4} = 0.5.$$

Con un valor p tan alto, no hay evidencia de que la diferencia observada sea distinta de lo que se esperaría por puro azar al reetiquetar los grupos.

9 Bootstrap: parecidos y diferencias con las permutaciones

Permutaciones y bootstrap son las dos técnicas de remuestreo del programa, y suelen confundirse porque ambas remuestran los datos observados en vez de asumir una forma distribucional. La diferencia importante no es mecánica (con o sin reemplazo) sino **qué pregunta de inferencia** responde cada una, lo cual depende de **dónde vive la aleatoriedad** en el estudio.

Bootstrap

Dada una muestra observada, se generan K remuestras **con reemplazo**, del mismo tamaño que la muestra original, extraídas de esa misma muestra. En cada remuestra se calcula el estadístico de interés (una media, una diferencia de medias, un coeficiente). La distribución de esos K valores aproxima la distribución muestral real del estadístico.

Dónde vive la aleatoriedad: la pregunta que decide cuál usar

- **Permutaciones** → **diseños experimentales**. La aleatoriedad proviene de la **asignación** de sujetos (que ya se asumen comparables) a los distintos grupos o tratamientos. La estructura típica es: selección de sujetos, asignación aleatoria a grupos, aplicación del tratamiento, comparación de resultados.
- **Bootstrap** → **diseños muestrales**. La aleatoriedad proviene del **proceso de muestreo** de cada población, no de cómo se asignaron los sujetos a grupos. La estructura típica es: se obtienen dos muestras aleatorias de dos poblaciones distintas y se comparan, sin que haya un proceso de asignación de por medio.

La diferencia práctica más importante: intervalos de confianza

Cuando se usan para obtener un valor p , ambos métodos compiten; pero solo el bootstrap permite construir **intervalos de confianza** para la verdadera diferencia entre poblaciones.

- El bootstrap, al remuestrear **cada muestra por separado**, genera una aproximación completa a la distribución muestral del estadístico, la cual se puede usar directamente para acotar el parámetro con una seguridad dada.
- Las permutaciones, al mezclar las etiquetas de los dos grupos bajo H_0 , solo generan la distribución **nula** del estadístico (qué tan grande sería la diferencia si no hubiera ninguna). Esa distribución nula no representa la verdadera variabilidad muestral del parámetro cuando H_0 es falsa, así que no sirve para construir un intervalo de confianza de la diferencia real.

Regla mnemotécnica

Si los sujetos fueron **asignados** a los grupos por el investigador $\Rightarrow$ permutación. Si los grupos ya **existían** en la población y solo se muestrearon por separado $\Rightarrow$ bootstrap. El anteproyecto de filtración de agua, por ejemplo, al asignar aleatoriamente combinaciones de material y volumen dentro de cada bloque, corresponde al caso de permutación si en algún momento se quisiera validar un contraste sin asumir normalidad.

10 Soluciones ante violaciones de supuestos

10.1 Mínimos cuadrados ponderados (WLS)

Cuando **no hay homocedasticidad pero sí hay normalidad**, la salida no es transformar ni ir a no paramétricos: es ponderar.

Idea

A cada tratamiento se le asigna un peso **inversamente proporcional** a su varianza muestral:

$$w_j = \frac{1}{s_j^2}.$$

Un tratamiento con mucha variabilidad (poca información confiable) recibe menos peso; uno con poca variabilidad (datos más “apretados” alrededor de su media) recibe más peso.

Cálculo numérico de pesos

Con tres grupos de tratamientos, cada uno con r réplicas y varianza muestral s_j^2 :

Grupo	s_j^2	$w_j = 1/s_j^2$
1 (3 obs.)	2.5	$1/2.5 = 0.4$
2 (3 obs.)	10	$1/10 = 0.1$
3 (3 obs.)	6	$1/6 \approx 0.17$

El grupo con mayor varianza (10) recibe el menor peso (0.1); el de menor varianza (2.5) recibe el mayor peso (0.4). En la práctica, para no repetir `base$res` sobre todo el data frame, se construye un vector de pesos por observación con `with(base, ...)`, donde por ejemplo el primer grupo de observaciones recibe peso 0.26 y el grupo con menor variabilidad llega a recibir hasta 0.32 (mayor peso), según la varianza estimada de cada subconjunto.

$$W = \text{diag}(w_1, \dots, w_n), \quad \hat{\beta}_{\text{WLS}} = (X'WX)^{-1}(X'WY) \quad \text{vs.} \quad \hat{\beta}_{\text{OLS}} = (X'X)^{-1}(X'Y). \quad (5)$$

OLS como caso particular

Mínimos cuadrados ordinarios (OLS) es el caso en que W es la matriz identidad: todas las observaciones pesan lo mismo, lo cual solo es razonable bajo homocedasticidad.

10.2 Transformaciones de la respuesta

Cuando no hay normalidad, antes de saltar a no paramétricos conviene intentar una transformación que acerque la respuesta a la normal: logarítmica ($\ln y$, cuando la varianza crece con la media), raíz cuadrada (datos de conteo) o Box–Cox (se estima el exponente λ que mejor normaliza). También cabe usar un **modelo específico** para la distribución conocida de la variable (por ejemplo, un GLM Poisson si la respuesta es un conteo), en vez de forzar la normalidad con una transformación.

11 Diferencia relevante y potencia

11.1 ¿Qué tan diferente es “diferente”?

Matemáticamente la igualdad válida bajo H_0 es $\mu_1 = \mu_2$, pero en la práctica existen diferencias tan pequeñas que no importan para la aplicación. El investigador debe definir, **antes** de recolectar datos, cuál es la **diferencia relevante** δ : la magnitud a partir de la cual una diferencia entre promedios sí le importa.




Figura 5: Misma forma distribucional, distinta separación entre medias. Con $\delta = 10$ las poblaciones son claramente distinguibles; con $\delta = 5$ se traslapan fuertemente, y detectar esa diferencia exige mucha más información (más réplicas o menos varianza).

Detectabilidad δ

Si el investigador define que una diferencia es relevante a partir de $\delta = 5$ unidades, y dos poblaciones tienen $\mu_1 = 65$, $\mu_2 = 70$, esas poblaciones difieren de una forma importante para la aplicación.

11.2 Error tipo II y potencia

Definiciones

Si se toman muestras de poblaciones cuyos promedios distan δ (magnitud relevante) y se prueba $H_0 : \mu_1 = \mu_2$, lo ideal es rechazar H_0 . Cuando no se rechaza a pesar de que las poblaciones sí difieren esa magnitud, se comete **error tipo II**.

$$\text{Potencia} = 1 - \beta = P(\text{rechazar } H_0 \mid H_0 \text{ falsa, diferencia} = \delta).$$

Qué mueve la potencia

Si la variabilidad de la respuesta es alta, es más difícil detectar diferencias de magnitud δ aunque existan. La solución directa para contrarrestar mucha variabilidad es **aumentar el número de réplicas**: así la prueba gana potencia y es más probable detectar diferencias que en realidad existen.

12 Estudios de simulación para calcular potencia

12.1 Lógica general

Un estudio de simulación parte de un modelo supuesto, genera datos artificiales siguiendo ese modelo mediante un proceso aleatorio, y repite el proceso muchas veces (**iteraciones**). Lo que se puede variar entre **escenarios** de simulación:

- Los coeficientes (las medias μ_j).
- La varianza del error, o si esa varianza es **común** (homocedasticidad) o distinta por tratamiento (heterocedasticidad).
- La distribución del error (o de la respuesta condicional).
- El número de réplicas por tratamiento.

Condición indispensable

Para que la simulación sirva para estimar potencia, el modelo del que se parte debe construirse de forma que la hipótesis nula sea **falsa a propósito**, fijando la diferencia relevante δ entre las medias generadas. Por ejemplo, con tres niveles:

$$\mu_2 = \mu_1 + \delta, \quad \mu_3 = \mu_1 + \delta/2.$$

El valor μ_1 se elige arbitrariamente; lo que importa es la **separación relativa** entre las medias.

Lo que se hace en cada iteración

1. Se generan datos $Y \mid j \sim \mathcal{N}(\mu_j, \sigma_\varepsilon^2)$ (homocedástico) o con σ_j^2 distinto por grupo (heterocedástico) si se quiere ese escenario.

2. Se ajusta el modelo (`lm`) y se extrae el valor p de la prueba de interés (por ejemplo, del ANOVA).
3. Se repite K veces (alto número de iteraciones), guardando cada valor p en un vector.
4. La potencia estimada es la **proporción de veces** que se rechazó H_0 :

$$\widehat{\text{Potencia}} = \text{mean}(p < 0.05).$$

12.2 Código en R: simulación de potencia para un factor

A continuación el flujo completo, comentado bloque por bloque.

Qué hace cada parte

- F1 es el factor de diseño, repetido según el número de réplicas r : cada nivel se repite r veces consecutivas.
- `mu[F1]` indexa el vector de medias usando F1 como índice, repitiendo cada μ_i tantas veces como corresponda según la “dinámica” de F1.
- Lo más importante de toda la simulación es d (la diferencia relevante δ): es lo que separa las medias y define qué tan falsa es H_0 en el escenario simulado.
- El `for` repite el proceso K veces; en cada vuelta se generan datos nuevos, se ajusta el modelo y se guarda el valor p del ANOVA en la posición correspondiente del vector `p`.

```
k <- 4          # numero de niveles del factor
r <- 5          # repeticiones por nivel
d <- 2          # diferencia relevante (delta) entre medias consecutivas
mu <- c(0, d, mu[2]+d/2*0 + d, mu[3]+d*0) # vector ilustrativo de medias

F1 <- factor(rep(1:k, each = r)) # factor de diseno, repetido r veces c/u

set.seed(10)
p <- c()        # vector vacio donde se guardan los p-valores
K <- 1000       # numero de iteraciones de la simulacion

for (i in 1:K) {
  y <- rnorm(n, mu[F1], sigma) # se generan los datos segun el modelo
  mod <- lm(y ~ F1)            # se ajusta el modelo clasico
  p[i] <- anova(mod)[1, 5]      # se guarda el p-valor del factor F1
}
```

```
mean(p < 0.05)    # proporción de veces que se rechaza Ho: la potencia estimada
```

Interpretación del resultado

Si se obtiene, por ejemplo, $\hat{\beta} = 0.47$, eso significa que la probabilidad de rechazar H_0 cuando las medias en realidad difieren δ o más es de 47%. Esa proporción es la potencia estimada de la prueba bajo ese escenario; representa qué tan seguido, si se repitiera el proyecto muchas veces bajo esas condiciones, se lograría detectar la diferencia que en realidad existe.

12.3 Atajo analítico: la función `power.anova.test`

Programar el ciclo `for` de la sección anterior es útil para entender qué es la potencia, pero en la práctica existe un atajo analítico (sin simular nada) para el caso de un factor balanceado con homocedasticidad: la función `power.anova.test` de la librería `pwr`.

Argumentos de `power.anova.test`

- **groups**: número de niveles del factor de diseño.
- **n**: número de réplicas por nivel (diseño balanceado).
- **between.var**: la varianza **entre** las medias hipotéticas, es decir, $\text{var}(\mu_1, \dots, \mu_k)$ calculada como varianza muestral del vector de medias verdaderas que el investigador propone.
- **within.var**: la varianza del error, σ^2 ; en la práctica se reemplaza por su estimación, el cuadrado medio residual (CMRes) de un modelo ya ajustado, ligeramente **aumentado** para ser conservador.
- **power**: si se omite **n** y se fija **power**, la función **invierte el problema** y devuelve el **n** (réplicas por tratamiento) necesario para alcanzar esa potencia.

Limitante importante: la función exige diseño **balanceado** y asume **homocedasticidad**; no sirve directamente para bloques desbalanceados ni para escenarios heterocedásticos.

Potencia hacia adelante: ejemplo de las manzanas

Con $k = 4$ tratamientos para evitar el pardeamiento de manzanas cortadas, $r = 5$ réplicas por tratamiento, una diferencia relevante de $\delta = 2$ puntos de color (medias hipotéticas $\mu = (3, 3, 2, 4)$) y varianza del error estimada en CMRes ≈ 0.98 (redondeada a 1 por conservadurismo):

```
power.anova.test(n=5, groups=4, between.var=var(mu1), within.var=1)
```

da como resultado una potencia de 0.64. Esto significa que, si se repitiera el experimento muchísimas veces y la diferencia real entre algún par de medias fuera de al menos 2 puntos, en el 64% de las repeticiones se lograría concluir correctamente que hay diferencias, y en el 36% restante no se lograría, aun existiendo el efecto.

Problema inverso: determinación del tamaño de muestra

Si en vez de fijar n se quiere una potencia de 0.90 para detectar esa misma diferencia de 2 puntos, se quita n del llamado y se agrega `power`:

```
power.anova.test(groups=4, between.var=var(mu1),  
                 within.var=1, power=0.9)
```

El resultado, extraído con `$n`, indica que se necesitan **al menos 9 réplicas por tratamiento** para asegurar esa potencia (contra las 5 que se tenían originalmente). Éste es precisamente el problema de **determinación del tamaño de muestra**: en vez de preguntar “¿qué tan probable es detectar la diferencia con los datos que ya tengo?”, se pregunta “¿cuántos datos necesito para que detectarla sea suficientemente probable?”

Por qué `between.var` es siempre una aproximación

En la práctica nunca se conocen las medias verdaderas μ_j , así que `between.var` depende de qué vector hipotético de medias se proponga, y existen infinitas combinaciones de medias que producen la misma diferencia relevante δ entre el par más separado. Por ejemplo, con $\delta = 2$ y $k = 4$ grupos, colocar las dos medias extremas en el centro (`c(2,4,3,3)`) da una `between.var` mucho menor que ponerlas en los extremos (`c(2,2,4,4)`): con menos variabilidad entre medias se necesitan **más** réplicas para la misma potencia, y con más variabilidad entre medias se necesitan **menos**. Por eso conviene probar varios vectores intermedios y reportar un rango de tamaños de muestra, no un solo número.

12.4 Extensión a diseños factoriales

El programa pide explícitamente la potencia en diseños **factoriales**, no solo de un factor. La simulación por `for` se extiende de forma directa cambiando el modelo (`lm(y~A+B)` sin interacción, o `lm(y~A*B)` con interacción, extrayendo la fila correspondiente del `anova`). El atajo analítico con `power.anova.test` también se extiende, con un truco conceptual importante según haya o no interacción.

El truco: ¿cuál es el verdadero “groups”?

`power.anova.test` fue pensada para un solo factor, pero se reutiliza para dos factores entendiendo qué comparación específica interesa:

- **Sin interacción**: si lo que interesa es la potencia para detectar diferencias **entre**

los niveles de un factor (ignorando el otro), `groups` es el número de niveles de ese factor, `n` es el número de réplicas que tiene cada uno de sus niveles **sin importar el nivel del otro factor**, y `within.var` es el CMRes del modelo completo `lm(y~A+B)`.

- **Con interacción:** si los factores interactúan, la comparación entre niveles de un factor **depende** del nivel del otro, así que hay que evaluar la potencia **dentro de cada nivel del factor que no es de interés** por separado: `groups` es el número de niveles del factor de interés, `n` es el número de réplicas **dentro de esa combinación específica**, y `within.var` es el CMRes del modelo con interacción `lm(y~A*B)`.

Tortugas: dos factores sin interacción

Se mide proteína en sangre según género (macho/hembra) y condición de alimento (dieta/abundancia), sin interacción entre ambos factores. Hay $r = 8$ tortugas por nivel de alimento (sin importar género) y $\text{CMRes} = 6.97$ del modelo `lm(proteina~genero+cond)`. Con medias hipotéticas $\mu = (30, 32)$ (diferencia relevante de 2 gr/dl):

```
power.anova.test(n=8, groups=2, between.var=var(mu), within.var=6.97)
```

da una potencia de solo 0.29: el experimento difícilmente detectaría un efecto real de la dieta. Repitiendo el cálculo sin fijar `n` y pidiendo `power=0.9`, se obtiene $n \approx 37.6$, es decir, se necesitarían **38 tortugas por condición** para alcanzar esa potencia.

Tortugas: dos factores con interacción

En un segundo estudio hay interacción entre especie y condición de alimento (dieta estricta, balanceada, abundancia), con $r = 4$ réplicas por combinación especie-condición y $\text{CMRes} = 2.56$ del modelo `lm(proteina~cond*especie)`. Como hay interacción, la comparación entre niveles de condición debe hacerse **dentro de cada especie**, así que `groups` son los 3 niveles de condición y `n=4` son las réplicas dentro de esa especie:

```
power.anova.test(n=4, groups=3, between.var=var(c(30,31,32)),  
within.var=2.56)
```

da una potencia de apenas 0.25 para detectar diferencias de 2 gr/dl. Sin embargo, si la diferencia real fuera mucho mayor (medias hipotéticas (30, 33.5, 37), es decir, diferencias de 7 gr/dl), con solo $n \approx 2.9$ (3 réplicas por tratamiento) ya se alcanza una potencia de 0.95. Esto ilustra un punto conceptual central: cuando la magnitud real del efecto es mucho mayor que el nivel de resolución δ que se había fijado, detectarlo es fácil incluso con pocos datos; el problema de potencia aparece específicamente cuando se quiere detectar diferencias **cerca** del límite de lo que se considera relevante.

12.5 Extensión a diseños con bloques

La lógica se extiende agregando el efecto de bloque a los datos ya generados. Con un factor de $k = 3$ niveles y $b = 4$ bloques, se generan 4 valores de cada distribución $Y|1, Y|2, Y|3$ (los 12 en total se acomodan en bloques, uno de cada nivel por bloque), y se asume:

$$\gamma_k \sim \mathcal{N}(0, \sigma_\gamma^2). \quad (6)$$

Cada γ_k se suma a todos los valores que caen en el bloque k .

Qué controla σ_γ^2

σ_γ^2 controla qué tan diferentes son los promedios de los bloques entre sí. Si σ_γ^2 es muy bajo, el diseño de bloques generado no sería muy distinto de uno sin bloques: el bloqueo solo aporta cuando los bloques de verdad difieren.

Nivel	Bloque	Media cond.	Efecto bloque	Y final
1	1	μ_1	γ_1	$Y_{11} + \gamma_1$
1	2	μ_1	γ_2	$Y_{12} + \gamma_2$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
3	4	μ_3	γ_4	$Y_{34} + \gamma_4$

Todos los Y_{ij} (antes de sumar el efecto de bloque) vienen de la misma distribución $\mathcal{N}(\mu_i, \sigma_\epsilon^2)$: lo que cambia entre filas de la tabla es solamente cuál γ_k se suma al final, según el bloque al que quedó asignada esa observación.

13 Análisis de covariancia (ANCOVA)

13.1 Motivación

En el diseño de un experimento se busca controlar las variables que introducen ruido en la respuesta, pero muchas veces existen variables que **no se pueden controlar** y aun así se pueden **medir** durante el experimento. Estas se llaman **concomitantes** o **covariables**, y son de interés cuando muestran una alta correlación con la respuesta. Su consideración reduce la variabilidad del error experimental, de un modo similar a la formación de bloques.

Ejemplo motivador

Al estudiar el efecto de varios tipos de entrenamiento sobre el desempeño de deportistas, las características antropométricas seguramente favorecen a algunos deportistas. Escoger deportistas idénticos en todo es prácticamente imposible; en cambio, se asignan aleatoriamente a los tratamientos y se **registran** esas medidas para tomarlas en cuenta después en el análisis.

13.2 Modelo con covariables

$$\mu_i = \beta_0 + \beta_1 X + \alpha_i. \quad (7)$$

Lectura de cada término

- β_0 : una **constante**, no representa una media como en otros modelos (a diferencia de μ en los modelos de tratamientos sin covariable).
- β_1 : coeficiente de regresión para la covariable X , común a todos los tratamientos.
- α_i : efecto del i -ésimo nivel del factor de diseño.

El modelo se extiende sin problema a más de una covariable, ya que en esencia sigue siendo un modelo de regresión.

Supuesto crítico: sin interacción factor-covariable

Se asume que **no hay interacción** entre el factor de diseño y la covariable: la pendiente β_1 es la **misma** para todos los tratamientos. Geométricamente, las rectas de regresión de cada tratamiento son **paralelas**. Este supuesto adicional es exactamente lo que se verifica formalmente en la Sección 13.6.

13.3 Comparación condicional de promedios

Gracias a la ausencia de interacción, comparar dos tratamientos es directo: se comparan los promedios de la respuesta **asumiendo el mismo valor de la covariable** para ambos.

$$\mu_1 - \mu_2 = (\beta_0 + \beta_1 X + \alpha_1) - (\beta_0 + \beta_1 X + \alpha_2) = \alpha_1 - \alpha_2. \quad (8)$$

El X se cancela exactamente porque la pendiente es común: por eso la diferencia entre tratamientos no depende de en qué valor de la covariable se evalúe.

13.4 Por qué importa mirar un intervalo pequeño de la covariable




Figura 6: Mismo conjunto de datos. *Izquierda*: visto en todo el rango de la covariable, la gran variabilidad **dentro** de cada tratamiento hace difícil ver la diferencia entre A y B. *Derecha*: al restringirse a un intervalo pequeño de la covariable (aproximación a la distribución condicional para un valor fijo), la diferencia entre tratamientos se vuelve evidente. Ambos paneles mantienen el mismo rango de respuesta para que sean comparables.

Lectura

Restringir a un intervalo pequeño de X es una **aproximación empírica** a comparar las distribuciones condicionales de la respuesta para un valor fijo de la covariable. El ANCOVA formaliza esta idea sin necesidad de tener muchísimos datos concentrados en un solo valor de X : usa **todos** los datos y la regresión para inferir esa comparación condicional.

13.5 Análisis formal: separar la variabilidad de la covariable

Para poner a prueba el efecto del factor de diseño, primero hay que **extraer** la variabilidad que introduce la covariable. Por eso no se calcula la suma de cuadrados de tratamiento de la forma usual; en su lugar se comparan las sumas de cuadrados residuales de **dos** modelos:

Modelo	Qué incluye
ω (reducido)	solo la covariable: $Y = \beta_0 + \beta_1 X + \varepsilon \rightarrow \text{SCRes}_\omega$
Ω (completo)	covariable y factor de diseño: $Y = \beta_0 + \beta_1 X + \alpha_i + \varepsilon \rightarrow \text{SCRes}_\Omega$

Suma de cuadrados de regresión marginal

$$\text{SCRegM} = \text{SCRes}_\omega - \text{SCRes}_\Omega. \quad (9)$$

Representa la porción de variabilidad total explicada por el factor de diseño, **una vez que ya se tomó en cuenta** la covariable. Si el factor sí tiene efecto sobre la respuesta promedio, SCRegM debe ser grande: agregar α_i al modelo debe reducir bastante el residuo respecto al modelo que solo tenía la covariable.

$$F = \frac{\text{SCRegM}/\text{dif.gl}}{\text{CMRes}_\Omega} = \frac{(\text{SCRes}_\omega - \text{SCRes}_\Omega)/(\text{gl}_\omega - \text{gl}_\Omega)}{\text{SCRes}_\Omega/\text{gl}_\Omega}, \quad (10)$$

donde $\text{dif.gl} = \text{gl}_\omega - \text{gl}_\Omega$ son los grados de libertad que “cuesta” agregar el factor (el número de parámetros α_i libres que se suman al pasar de ω a Ω).

Por qué este F y no el clásico

Esta es la misma lógica de comparar un modelo reducido contra uno completo que aparece en cualquier prueba de hipótesis anidada: si $\alpha_i = 0$ para todo i (el factor no aporta nada), ambos modelos deberían explicar prácticamente lo mismo y $F \approx 1$. Si el factor sí aporta, el modelo completo reduce sustancialmente el residuo y F crece. Esta misma lógica de comparar un modelo “chico” contra uno “grande” es exactamente la que se reutiliza en la Sección 13.6 para probar el supuesto de paralelismo, solo que ahí el parámetro adicional no es α_i sino el término de interacción $\text{factor} \times \text{covariable}$.

13.6 Verificación formal del supuesto de paralelismo

La Sección 13 (modelo con covariables) impuso por construcción que la pendiente β_1 fuera la misma para todos los tratamientos. Ese supuesto se puede — y se debe — poner a prueba formalmente, no solo verificar de forma gráfica viendo si las rectas **parecen** paralelas.

Modelo ampliado con interacción

Se agrega al modelo un término de interacción entre el factor de diseño y la covariable, permitiendo que cada tratamiento tenga su **propia** pendiente γ_i además de su propio intercepto α_i :

$$\mu_i = \beta_0 + \beta_1 X + \alpha_i + \gamma_i X. \quad (11)$$

El supuesto de paralelismo equivale exactamente a

$$H_0 : \gamma_1 = \gamma_2 = \cdots = \gamma_k = 0$$

(todas las pendientes específicas por tratamiento son cero, es decir, todos comparten la misma pendiente β_1).

Cómo se prueba: el mismo esquema ω contra Ω

Se reutiliza exactamente la comparación de modelos anidados de la Sección 13, ahora con otro par de modelos:

Modelo	Qué incluye
ω (paralelismo)	covariable y factor, sin interacción: $Y = \beta_0 + \beta_1 X + \alpha_i + \varepsilon$
Ω (pendientes libres)	covariable, factor y su interacción: $Y = \beta_0 + \beta_1 X + \alpha_i + \gamma_i X + \varepsilon$

En R esto es directamente `anova(mod_omega, mod_Omega)` entre `lm(Y~X+factor)` y `lm(Y~X*factor)`. Si el término de interacción **no** es significativo, no se rechaza H_0 y **se puede asumir paralelismo**: vale el análisis simplificado de la Sección 13. Si **sí** es significativo, se rechaza el paralelismo y la interpretación de las diferencias entre tratamientos se complica, como se desarrolla a continuación.

Verificación gráfica previa

Antes de la prueba formal conviene graficar las rectas de regresión de cada tratamiento superpuestas. Si a simple vista las pendientes van en direcciones claramente distintas, ya hay una señal de alerta que la prueba formal va a confirmar; pero la inspección visual sola **no sustituye** la prueba, porque pendientes que se ven parecidas pueden ser, o no, estadísticamente distintas según la variabilidad de los datos.

13.7 Comparación de tratamientos cuando no hay paralelismo

Si se rechaza H_0 en la Sección 13.6, la simplificación de la Ecuación de la Sección 13 ($\mu_1 - \mu_2 = \alpha_1 - \alpha_2$, válida para cualquier X) deja de ser cierta, porque el término $\beta_1 X$ **ya no se cancela**: la diferencia entre tratamientos ahora depende de **en qué valor de la covariable** se evalúe.

Diferencia condicional con pendientes distintas

Con el modelo ampliado $\mu_i = \beta_0 + \beta_1 X + \alpha_i + \gamma_i X$, la diferencia esperada entre los tratamientos i y j , evaluada en un valor específico $X = x_0$ de la covariable, es:

$$\begin{aligned}\mu_i(x_0) - \mu_j(x_0) &= [\beta_0 + \beta_1 x_0 + \alpha_i + \gamma_i x_0] - [\beta_0 + \beta_1 x_0 + \alpha_j + \gamma_j x_0] \\ &= (\alpha_i - \alpha_j) + (\gamma_i - \gamma_j) x_0.\end{aligned}$$

A diferencia del caso con paralelismo, esta diferencia **cambia** según el valor x_0 que se elija: tiene un término constante $(\alpha_i - \alpha_j)$ más un término que crece o decrece linealmente con x_0 .

Cálculo numérico

Supóngase que para los tratamientos 1 y 2 se estima $\alpha_1 - \alpha_2 = 6.84$ y $\gamma_1 - \gamma_2 = 1.15$ (con la covariable centrada en su media muestral, $\bar{X} = 25$). La diferencia esperada entre ambos tratamientos, evaluada en dos valores distintos de la covariable, es:

$$\begin{aligned}\mu_1(20) - \mu_2(20) &= 6.84 + 1.15(20 - 25) = 6.84 - 5.75 = 1.09, \\ \mu_1(30) - \mu_2(30) &= 6.84 + 1.15(30 - 25) = 6.84 + 5.75 = 12.59.\end{aligned}$$

La diferencia entre tratamientos pasa de apenas 1.09 unidades cuando $X = 20$ a casi 12.6 unidades cuando $X = 30$: por eso, cuando no hay paralelismo, no tiene sentido reportar “la” diferencia entre dos tratamientos sin especificar a qué nivel de la covariable corresponde.

Consecuencia práctica

Sin paralelismo, cualquier intervalo de confianza o conclusión sobre “el tratamiento 1 es mejor que el 2” debe acompañarse **siempre** del valor de la covariable para el cual se hizo la comparación, porque en otro valor de X la conclusión podría cambiar de magnitud, desaparecer, o incluso invertirse si las rectas llegan a cruzarse dentro del rango observado de X .

13.8 Ejemplo: carrera de 100 metros

Estudio para examinar el efecto de la **posición de salida** y el **tipo de calentamiento** sobre el tiempo en recorrer 100 metros planos, en población de 17 a 24 años. Factores de diseño:

- Calentamiento: (A) solo estiramiento, (B) calentamiento normal para ejercicio regular, (C) calentamiento específico para correr.
- Salida: (+) salida baja con 4 apoyos, (−) salida normal de pie.

La covariable y por qué se incluye

Hay estudiantes más grandes que otros y con pesos distintos; esa heterogeneidad antropométrica no es controlable por diseño, así que se mide el peso P y la estatura E de cada participante y se calcula el índice de masa corporal:

$$\text{IMC} = \frac{P}{E^2}.$$

El IMC se incluye porque el tiempo en la carrera está asociado **linealmente** a esta covariable, algo que se verifica gráficamente y con el coeficiente de correlación de Pearson antes de confiar en el modelo.

$$r_{\text{Pearson}} = \frac{\text{Cov}(X, Y)}{S_X S_Y}, \quad -1 \leq r \leq 1. \quad (12)$$

Verificación previa indispensable

Antes de meter el IMC como covariable hay que confirmar que la relación tiempo-IMC es lineal **dentro de cada tratamiento**, no solo en general. Se grafica respuesta vs. covariable separado por combinación de calentamiento y salida, y se calcula el coeficiente de correlación dentro de cada grupo (por ejemplo, con `summarise(group_by(base,A,B), cor(X,Y))` en R). Si alguna combinación muestra una relación claramente no lineal, el modelo de ANCOVA clásico no es adecuado para esa estructura.

Bandas alrededor de la línea de tendencia

En el gráfico de tiempo vs. IMC, separado por nivel de glicerina o por tratamiento, se traza una banda de confianza alrededor de la línea de tendencia. Si la línea de un tratamiento se mantiene **dentro** de la banda de otro, la linealidad no se ve tan mal afectada; si se sale por completo, hay razón para sospechar de la linealidad o de la igualdad de pendientes entre tratamientos.

En este experimento, los investigadores consideraron que una diferencia de **2 segundos** entre promedios es la diferencia relevante ($\delta = 2$) a la hora de evaluar la potencia del diseño.

14 Flujo de análisis completo

Paso 1. Ajustar el modelo y extraer los residuos.

Paso 2. Verificar independencia (Sección 2): residuos vs. orden de recolección, vs. tiempo, vs. ubicación espacial. Buscar clusters o tendencias sistemáticas.

Paso 3. Verificar homocedasticidad (Levene/Bartlett) y, en paralelo, normalidad con QQ-plot, Shapiro–Wilk y K–S (Secciones 3 y 5).

Si hay normalidad y homocedasticidad:

↔ ANOVA clásico, Tukey si corresponde.

Si hay normalidad pero no homocedasticidad:

↔ Mínimos cuadrados ponderados (WLS) o ANOVA de Welch.

Si no hay normalidad:

↔ Intentar transformación (log, raíz, Box–Cox) o modelo específico.

↔ Si no funciona: método no paramétrico (K–W, Friedman con bloques, rangos alineados si hay interacción) o remuestreo (permutaciones si la aleatoriedad viene de la asignación a tratamientos; bootstrap si viene del muestreo de poblaciones, Sección 9).

Paso 4. Si hay una covariable medible y correlacionada con la respuesta, considerar ANCOVA: verificar linealidad dentro de cada tratamiento y el supuesto de paralelismo (Sección 13.6) antes de ajustar.

Paso 5. Definir la diferencia relevante δ **antes** de interpretar potencia; estimarla mediante simulación o, si el diseño es balanceado y homocedástico, con `power.anova.test` (Sección 12.3). Si la potencia resulta baja, usar la misma función con `power` fijo para determinar el tamaño de muestra necesario.

Referencias citadas

- Wobbrock, J. O., Findlater, L., Gergle, D., & Higgins, J. J. (2011). *The Aligned Rank Transform for Nonparametric Factorial Analyses Using Only ANOVA Procedures*. Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (CHI '11), 143–146. doi:10.1145/1978942.1978963
- Gao, X., & Alvo, M. (2005). *A unified nonparametric approach for unbalanced factorial designs*. Journal of the American Statistical Association, 100(471), 926–941. doi:10.1198/016214505000000042
- Tran, D. K., Wagaman, A. S., Nguyen, A., Jacobson, D., & Hartlaub, B. (2024). *Nonparametric tests for interaction in two-way ANOVA with balanced replications*. arXiv:2410.04700.